

UNIVERSIDAD NACIONAL MAYOR DE SAN MARCOS

(Universidad del Perú, DECANA DE AMÉRICA)

Facultad de Ingeniería de Sistemas e Informática

Escuela Profesional de Ingeniería de Software

PROYECTO GRUPAL (PG)

Asignatura: INTELIGENCIA DE NEGOCIOS

Instrucciones, lineamientos, rúbricas y autoevaluación

Solución integral de Inteligencia de Negocios sobre una empresa
ficticia con datos sintéticos, notebooks de Python y Power BI

Datos del curso	
Código de la asignatura	20W0802 (Plan 2018)
Ciclo / Semestre	VIII — 2026-1
Créditos / Modalidad	3 — Presencial
Componente de evaluación	Proyecto Grupal (PG) — Evaluación Continua
Integrantes por equipo	Mínimo 4 — Máximo 6
Docente	Mg. Juan Gamarra Moreno
Correo	juan.gamarra@unmsm.edu.pe

Lima — Perú

Contenido

Para actualizar el índice y los números de página, haga clic derecho sobre la tabla siguiente y seleccione «Actualizar campos» (o presione F9).

Contenido	2
1. Presentación del Proyecto Grupal	4
1.1 Las seis partes del proyecto	4
1.2 Vinculación con las competencias y logros del sílabo	4
1.3 Objetivos	4
2. Conformación de equipos y roles	6
2.1 Roles sugeridos	6
2.2 Bitácora y control de versiones	6
3. Cronograma y esquema de entregas	7
4. Caso de estudio: empresa ficticia	8
4.1 Caso de referencia: «AndesMarket S.A.C.»	8
4.2 Preguntas de negocio que la solución debe responder	8
4.3 Requisito de datos sintéticos	8
5. Herramientas, entorno y estructura del proyecto	9
5.1 Herramientas obligatorias	9
5.2 Estructura del repositorio	9
5.3 Buenas prácticas	9
6. Generación de datos sintéticos	11
6.1 Esquema de datos a generar	11
6.2 Reglas de realismo (distribuciones)	11
6.3 Problemas de calidad introducidos a propósito	11
7. Parte 1: Datamart analítico en BI	13
7.1 Pasos en Python (notebook 01_datamart_etl.ipynb)	13
7.2 Pasos en Power BI (AndesMarket.pbix)	14
7.3 Entregables de la Parte 1	14
8. Parte 2: Visualización de Datos en BI	15
8.1 Pasos en Power BI	15
8.2 Pasos en Python (notebook 02_visualizacion.ipynb)	15
8.3 Entregables de la Parte 2	16
9. Parte 3: Clasificación en BI	17
9.1 Pasos en Python (notebook 03_clasificacion.ipynb)	17
9.2 Integración con Power BI	18
9.3 Entregables de la Parte 3	18
10. Parte 4: Segmentación en BI	19
10.1 Pasos en Python (notebook 04_segmentacion.ipynb)	19
10.2 Integración con Power BI	19
10.3 Entregables de la Parte 4	20
11. Parte 5: Asociación en BI	21
11.1 Pasos en Python (notebook 05_asociacion.ipynb)	21
11.2 Integración con Power BI	21
11.3 Entregables de la Parte 5	21
12. Parte 6: Regresión en BI	23
12.1 Pasos en Python (notebook 06_regresion.ipynb)	23
12.2 Integración con Power BI	23
12.3 Entregables de la Parte 6	24
13. Documentación de prompts (ingeniería de prompts)	25
14. Entregables y formato de entrega	26
14.1 Lista de entregables (entrega final)	26
14.2 Formato del documento Word/PDF del informe	26
14.3 Nomenclatura y reglas de entrega	26

15. Rúbricas de evaluación	27
15.1 Estructura de calificación	27
15.2 Escala de niveles de desempeño	27
15.3 Rúbrica de la Parte 1 — Datamart analítico	27
15.4 Rúbrica de la Parte 2 — Visualización de datos	28
15.5 Rúbrica de la Parte 3 — Clasificación	29
15.6 Rúbrica de la Parte 4 — Segmentación	29
15.7 Rúbrica de la Parte 5 — Asociación	30
15.8 Rúbrica de la Parte 6 — Regresión	30
15.9 Rúbrica transversal (20%)	31
16. Cuadro de autoevaluación	32
16.1 Autoevaluación por componente	32
16.2 Lista de verificación detallada del cumplimiento	32
17. Integridad académica y uso responsable de IA	34
18. Anexos	35
Anexo A — Plantilla de registro de prompts	35
Anexo B — Prompts de generación de datos sintéticos	35
Anexo C — Estructura sugerida del informe consolidado	37
Anexo D — Lista de verificación final de entrega	37

1. Presentación del Proyecto Grupal

El Proyecto Grupal (PG) es el producto integrador de la asignatura Inteligencia de Negocios. A lo largo del semestre, cada equipo construirá una **solución completa de Business Intelligence (BI)** para una empresa ficticia, empleando de manera intensiva **notebooks de Python** para el procesamiento, modelado analítico y minería de datos, y **Power BI** para el modelado dimensional, la visualización y la entrega de tableros para la toma de decisiones gerenciales.

El proyecto se desarrolla en **seis (6) partes** que se entregan de forma incremental y que se corresponden con los productos del sílabo. Cada parte agrega una capa de valor analítico sobre la misma empresa y el mismo conjunto de datos sintéticos, de modo que al final el equipo disponga de una solución coherente, reproducible y orientada a negocio.

1.1 Las seis partes del proyecto

Parte	Producto	Foco analítico principal
Parte 1	Datamart analítico en BI	Modelo dimensional (esquema estrella), ETL y carga en Power BI
Parte 2	Visualización de Datos en BI	Medidas DAX, tablero ejecutivo y storytelling de datos
Parte 3	Clasificación en BI	Modelo supervisado para predecir abandono / propensión
Parte 4	Segmentación en BI	Clustering de clientes (RFM + K-Means) y perfilamiento
Parte 5	Asociación en BI	Reglas de asociación y análisis de canasta de mercado
Parte 6	Regresión en BI	Pronóstico de ventas/demanda y su tablero de seguimiento

1.2 Vinculación con las competencias y logros del sílabo

El PG evidencia el logro de las competencias técnicas CT 11.2 y CT 12.2, y los resultados de aprendizaje (RA) de la asignatura, según la siguiente correspondencia:

Parte del PG	Resultados de aprendizaje (RA) evidenciados
Parte 1 — Datamart	CT 12.2 RA2 (datamarts/DWH), RA3 (ETL), RA4 (modelo multidimensional)
Parte 2 — Visualización	CT 12.2 RA5 (visualización), RA1 (conceptos de BI)
Parte 3 — Clasificación	CT 11.2 RA7 (minería de datos), RA8 (técnicas avanzadas)
Parte 4 — Segmentación	CT 11.2 RA7 (minería de datos), RA8 (técnicas avanzadas)
Parte 5 — Asociación	CT 11.2 RA7 (minería de datos), RA8 (técnicas avanzadas)
Parte 6 — Regresión	CT 11.2 RA7 (minería de datos), RA8 (técnicas avanzadas), RA6 (Big Data en BI)

1.3 Objetivos

Objetivo general. Diseñar, construir y sustentar una solución integral de Inteligencia de Negocios para una empresa ficticia, que abarque desde el datamart analítico hasta los

modelos de minería de datos (clasificación, segmentación, asociación y regresión), generando información accionable para la toma de decisiones gerenciales.

Objetivos específicos:

- Diseñar e implementar un datamart con enfoque multidimensional y un proceso ETL reproducible en Python.
- Construir tableros de visualización en Power BI con medidas DAX que respondan preguntas de negocio.
- Desarrollar y evaluar modelos de clasificación, segmentación, asociación y regresión sobre el datamart.
- Generar y documentar datos sintéticos realistas, con problemas de calidad controlados, y los prompts utilizados.
- Comunicar hallazgos con rigor técnico y sentido de negocio, demostrando dominio individual y trabajo colaborativo.

2. Conformación de equipos y roles

El proyecto se desarrolla en equipos de **mínimo cuatro (4) y máximo seis (6) integrantes**. La conformación se realiza en la Semana 1 y se registra en el Aula Virtual. Una vez registrados, los equipos no podrán modificarse salvo autorización expresa del docente.

2.1 Roles sugeridos

Aunque todos los integrantes deben participar en el análisis y comprender la totalidad de la solución, se sugiere distribuir responsabilidades de coordinación. Un mismo integrante puede asumir más de un rol en equipos de cuatro personas.

Rol	Responsabilidades principales
Líder de proyecto	Coordina el cronograma, asigna tareas, controla los entregables y la comunicación con el docente.
Ingeniero(a) de datos	Lidera la generación de datos sintéticos, el ETL en Python y el diccionario de datos.
Arquitecto(a) de BI	Lidera el modelo dimensional, las relaciones y las medidas DAX en Power BI.
Científico(a) de datos	Lidera los modelos de minería (clasificación, segmentación, asociación, regresión) y su evaluación.
Analista de negocio	Traduce los resultados a insights y recomendaciones; cuida el storytelling y el valor para el negocio.
Editor(a) de documentación	Consolida el informe, el registro de prompts, el control de versiones y la bitácora del equipo.

Importante: la calificación contempla el dominio individual. Durante la sustentación, cualquier integrante podrá ser consultado sobre cualquier parte del proyecto. La división del trabajo no exime a nadie de comprender el conjunto.

2.2 Bitácora y control de versiones

- **Repositorio.** El equipo trabajará sobre un repositorio Git (por ejemplo, GitHub o GitLab) con la estructura de carpetas indicada en la sección 5. Todos los integrantes deben registrar commits.
- **Bitácora de trabajo.** Se llevará una bitácora (hoja de cálculo o archivo Markdown) con fecha, integrante, actividad realizada y tiempo dedicado. Esta bitácora es insumo de la rúbrica transversal.
- **Aporte equitativo.** Al cierre, cada equipo entrega una breve tabla de contribución por integrante (porcentaje aproximado y tareas), firmada por todos.

3. Cronograma y esquema de entregas

El PG se entrega de forma incremental en tres hitos alineados con el avance del sílabo. Cada hito acumula las partes anteriores ya corregidas. Las fechas exactas de cada entrega se publican en el Aula Virtual.

Hito	Semana referencial	Contenido de la entrega
Conformación	Semana 1	Registro del equipo, roles y propuesta de empresa ficticia (1 página).
Entrega 1	Semana 7	Parte 1 (Datamart) y Parte 2 (Visualización), con datos sintéticos y notebooks.
Entrega 2	Semana 12	Parte 3 (Clasificación) y Parte 4 (Segmentación).
Entrega 3 (final)	Semana 15	Parte 5 (Asociación), Parte 6 (Regresión), informe consolidado, anexo de prompts y sustentación.

Sustentación. En la Semana 15 cada equipo realiza una sustentación oral con apoyo de Power BI y de los notebooks. Se evalúa el dominio individual, la coherencia de la solución y la calidad de la comunicación.

Penalidades. La entrega fuera de plazo, los archivos que no abren o no ejecutan, y la ausencia del registro de prompts o de los datos sintéticos reproducibles, se penalizan según las rúbricas. No se aceptan entregas que no compilen/ejecuten de principio a fin.

4. Caso de estudio: empresa ficticia

Cada equipo trabaja sobre una **empresa ficticia** de su elección, siempre que el giro permita desarrollar las seis partes del proyecto. A continuación se describe un **caso de referencia** que el equipo puede adoptar tal cual o adaptar (cambiando rubro, nombre y contexto). Sea cual sea la decisión, el caso debe permitir: ventas transaccionales con detalle de ítems, clientes identificables, productos categorizados, dimensión temporal y promociones.

4.1 Caso de referencia: «AndesMarket S.A.C.»

AndesMarket S.A.C. es una cadena ficticia de retail omnicanal con sede en Lima que opera supermercados físicos en varias regiones del Perú y un canal de comercio electrónico. La empresa cuenta con un programa de fidelización («AndesPlus») que identifica a sus clientes recurrentes. La gerencia desea transformar sus datos transaccionales en decisiones: entender qué se vende y dónde, anticipar el abandono de clientes, segmentar su base, descubrir combinaciones de productos para promociones cruzadas y pronosticar la demanda.

Problemática. Hoy la información está dispersa en archivos operativos con inconsistencias (formatos de fecha mixtos, categorías mal escritas, registros duplicados y valores faltantes). No existe un repositorio analítico único ni tableros confiables, por lo que las decisiones se toman de forma intuitiva.

4.2 Preguntas de negocio que la solución debe responder

- ¿Cómo evolucionan las ventas y el margen por categoría, tienda, canal y periodo? (Partes 1 y 2)
- ¿Qué clientes tienen mayor probabilidad de abandonar el programa de fidelización? (Parte 3)
- ¿Qué segmentos de clientes existen y cómo debería tratarse a cada uno? (Parte 4)
- ¿Qué productos se compran juntos y qué promociones cruzadas conviene impulsar? (Parte 5)
- ¿Cuál será la demanda/venta esperada para planificar inventario y campañas? (Parte 6)

4.3 Requisito de datos sintéticos

Dado que la empresa es ficticia, **todos los datos deben ser sintéticos y generados por el equipo de forma reproducible** (con semilla fija). Está prohibido usar datos reales de empresas o personas. La generación de los datos, sus volúmenes, distribuciones y los problemas de calidad introducidos a propósito se especifican en la sección 6 y los prompts correspondientes se documentan en el Anexo B.

5. Herramientas, entorno y estructura del proyecto

5.1 Herramientas obligatorias

Herramienta	Uso en el proyecto
Python 3.10+ (notebooks Jupyter)	ETL, EDA, minería de datos, evaluación de modelos y generación de datos sintéticos.
Power BI Desktop	Modelo dimensional, relaciones, medidas DAX, tableros y publicación de resultados.
Git (GitHub/GitLab)	Control de versiones y trabajo colaborativo.
Tableau (opcional)	Puede complementar a Power BI, pero Power BI es la herramienta principal de BI.

Librerías de Python sugeridas: pandas, numpy, matplotlib, seaborn, plotly, scikit-learn, mlxtend (reglas de asociación), faker (datos sintéticos) y, opcionalmente, statsmodels.

5.2 Estructura del repositorio

El equipo organizará el proyecto con la siguiente estructura mínima de carpetas y archivos, que facilita la reproducibilidad y la corrección:

```
proyecto-bi-andesmarket/
├── README.md                # Descripción, integrantes, cómo ejecutar
├── requirements.txt         # Dependencias de Python (versiones)
├── data/
│   ├── raw/                # Datos sintéticos crudos (con problemas de calidad)
│   └── processed/          # Datos limpios listos para análisis y Power BI
├── notebooks/
│   ├── 00_generacion_datos.ipynb # Generación reproducible de datos sintéticos
│   ├── 01_datamart_etl.ipynb    # Parte 1: ETL y modelo dimensional
│   ├── 02_visualizacion.ipynb  # Parte 2: visualizaciones en Python
│   ├── 03_clasificacion.ipynb  # Parte 3
│   ├── 04_segmentacion.ipynb   # Parte 4
│   ├── 05_asociacion.ipynb     # Parte 5
│   └── 06_regresion.ipynb      # Parte 6
├── powerbi/
│   └── AndesMarket.pbix       # Modelo, medidas DAX y tableros
├── prompts/
│   └── registro_prompts.md    # Bitácora de prompts (Anexo A y B)
└── informe/
    └── Informe_PG_AndesMarket.pdf # Informe consolidado
```

Reproducibilidad. El archivo README.md debe indicar la versión de Python, cómo instalar dependencias (pip install -r requirements.txt) y el orden de ejecución de los notebooks. Cualquier persona debe poder regenerar los datos y reproducir los resultados ejecutando los notebooks en orden.

5.3 Buenas prácticas

- Fijar siempre una semilla aleatoria (por ejemplo, 42) para que datos y modelos sean reproducibles.
- Documentar cada notebook con celdas Markdown: objetivo, decisiones, interpretación de resultados.

- Separar datos crudos (con problemas) de datos procesados (limpios); nunca sobrescribir los crudos.
- Nombrar archivos y campos de forma consistente (sin tildes ni espacios en nombres de archivo).
- Versionar el .pbix y los notebooks; evitar archivos temporales y de gran tamaño innecesarios.

6. Generación de datos sintéticos

Los datos sintéticos son la base de todo el proyecto. Deben ser **realistas, coherentes entre tablas y reproducibles**, e incorporar de forma deliberada problemas de calidad para que el equipo practique limpieza y transformación (ETL). La generación se realiza en el notebook **00_generacion_datos.ipynb** y se documenta con prompts en el Anexo B.

6.1 Esquema de datos a generar

Se generan tablas de dimensiones y una tabla de hechos de ventas a nivel de detalle (línea de venta). Los volúmenes son referenciales y pueden ajustarse, manteniendo un tamaño suficiente para que los modelos tengan sentido (al menos dos años de operación).

Tabla	Volumen referencial	Campos principales
Dim_Cliente	~5,000 clientes	id_cliente, nombre, sexo, fecha_nacimiento, distrito, fecha_alta, segmento_programa
Dim_Producto	~500 productos	id_producto, nombre, categoria, subcategoria, marca, precio_lista, costo
Dim_Tienda	~15 tiendas	id_tienda, nombre, canal (físico/online), region, ciudad
Dim_Tiempo	~730 días	fecha, dia, mes, trimestre, anio, dia_semana, es_feriado
Dim_Promocion	~40 promociones	id_promocion, nombre, tipo, descuento_pct, fecha_inicio, fecha_fin
Fact_Ventas	~60,000 líneas	id_venta, fecha, id_cliente, id_producto, id_tienda, id_promocion, cantidad, precio_unitario, descuento

6.2 Reglas de realismo (distribuciones)

- **Estacionalidad.** Mayor volumen en julio (Fiestas Patrias) y diciembre (Navidad); caídas en meses de baja demanda.
- **Concentración (Pareto).** Alrededor del 20% de los productos concentra cerca del 80% de las ventas; pocos clientes muy frecuentes y muchos esporádicos.
- **Coherencia de precios.** El precio_unitario varía alrededor del precio_lista; el descuento aplica cuando hay promoción vigente.
- **Canasta.** Algunas categorías tienden a comprarse juntas (por ejemplo, snacks + bebidas), para que existan reglas de asociación con lift > 1.
- **Abandono (churn).** Una proporción de clientes (~20–25%) deja de comprar tras cierto periodo; este comportamiento se etiqueta para la Parte 3.

6.3 Problemas de calidad introducidos a propósito

Los datos crudos (carpeta data/raw) deben contener, de manera controlada, los siguientes problemas, que el ETL deberá detectar y corregir:

Problema de calidad	Cómo introducirlo	Tratamiento esperado en ETL
Fechas en formatos mixtos	Mezclar 'dd/mm/aaaa', 'aaaa-mm-dd' y texto	Parseo robusto y estandarización a tipo fecha
Valores faltantes	Nulos en descuento, distrito, categoría (~3–8%)	Imputación o reglas de negocio justificadas

Problema de calidad	Cómo introducirlo	Tratamiento esperado en ETL
Duplicados	Repetir ~1–2% de líneas de venta	Eliminación por clave (id_venta + id_producto)
Texto inconsistente	Categorías en mayúsculas/minúsculas y con espacios	Normalización (trim, mayúsculas, mapeo)
Errores de tipeo	Variantes como 'Lacteos', 'lácteos', 'LACTEOS'	Diccionario de homologación de categorías
Outliers	Cantidades o precios extremos poco realistas	Detección y tratamiento (recorte o revisión)
Claves huérfanas	id_producto en ventas inexistente en Dim_Producto	Validación de integridad referencial

Registro de calidad. El notebook de ETL debe reportar, antes y después de la limpieza, métricas de calidad: número de nulos, duplicados, claves huérfanas y filas afectadas. Esto evidencia el valor del proceso de transformación.

Prompts de generación. Los prompts utilizados para diseñar y generar estos datos (incluyendo volúmenes, distribuciones y problemas de calidad) se documentan en detalle en el **Anexo B**. Su inclusión es obligatoria y forma parte de la calificación.

7. Parte 1: Datamart analítico en BI

Aspecto	Detalle
Resultado de aprendizaje	CT 12.2 RA2, RA3, RA4 — Datamarts/DWH, ETL y modelo multidimensional
Objetivo de la parte	Diseñar e implementar un datamart con esquema estrella para AndesMarket, ejecutar el ETL en Python y cargar el modelo en Power BI.
Herramientas	Python (notebook) + Power BI (modelo, DAX y tablero)

7.1 Pasos en Python (notebook 01_datamart_etl.ipynb)

1. **Definir el proceso de negocio y el grano.** Modelar el proceso de ventas; el grano es la línea de venta (un producto dentro de una boleta).
2. **Identificar dimensiones y hechos.** Dimensiones: Cliente, Producto, Tienda, Tiempo y Promoción. Hechos/métricas: cantidad, precio unitario, descuento, importe, costo y margen.
3. **Cargar los datos crudos** desde data/raw y reportar métricas de calidad iniciales (nulos, duplicados, claves huérfanas).
4. **Aplicar el ETL:** estandarizar fechas, normalizar texto/categorías, eliminar duplicados, tratar nulos y validar integridad referencial.
5. **Derivar métricas calculadas** (importe = cantidad × precio_unitario × (1 – descuento); margen = importe – costo).
6. **Construir las tablas dimensionales y la tabla de hechos** y exportarlas limpias a data/processed (un CSV por tabla).
7. **Elaborar el diccionario de datos** (campo, tipo, descripción y clave) y el diagrama del esquema estrella.

Ejemplo de ETL en Python:

```
import pandas as pd
import numpy as np

# 1) Carga de datos crudos (con problemas de calidad)
ventas = pd.read_csv("data/raw/ventas.csv", sep=";", encoding="utf-8")
print("Filas:", len(ventas), "| Duplicados:", ventas.duplicated().sum())

# 2) Estandarización de fechas (formatos mixtos -> fecha)
ventas["fecha"] = pd.to_datetime(ventas["fecha"], errors="coerce", dayfirst=True)

# 3) Normalización de texto y homologación de categorías
ventas["categoria"] = ventas["categoria"].str.strip().str.upper()
homologa = {"LACTEOS": "LÁCTEOS", "LÁCTEOS": "LÁCTEOS"}
ventas["categoria"] = ventas["categoria"].replace(homologa)

# 4) Eliminación de duplicados por clave de negocio
ventas = ventas.drop_duplicates(subset=["id_venta", "id_producto"])

# 5) Tratamiento de nulos según regla de negocio
ventas["descuento"] = ventas["descuento"].fillna(0)

# 6) Validación de integridad referencial
productos = pd.read_csv("data/processed/dim_producto.csv")
```

```
ventas = ventas[ventas["id_producto"].isin(productos["id_producto"])]

# 7) Métricas derivadas
ventas = ventas[ventas["cantidad"] > 0]
ventas["importe"] = ventas["cantidad"] * ventas["precio_unitario"] * (1 -
ventas["descuento"])

ventas.to_csv("data/processed/fact_ventas.csv", index=False)
```

7.2 Pasos en Power BI (AndesMarket.pbix)

1. **Importar las tablas limpias** desde data/processed (Obtener datos → Texto/CSV).
2. **Crear la dimensión calendario** (tabla de fechas marcada como tabla de fechas) si no se importó Dim_Tiempo.
3. **Definir las relaciones** uno-a-muchos entre cada dimensión y la tabla de hechos, formando el esquema estrella.
4. **Verificar cardinalidad y dirección del filtro** y ocultar columnas técnicas (claves) de la vista de informe.
5. **Documentar el modelo** con una captura del diagrama de relaciones para incluir en el informe.

7.3 Entregables de la Parte 1

- Notebook 01_datamart_etl.ipynb ejecutado, con reporte de calidad antes/después.
- Tablas limpias en data/processed y diccionario de datos.
- Diagrama del esquema estrella y captura del modelo en Power BI.
- Prompts utilizados en esta parte, registrados según el Anexo A.

8. Parte 2: Visualización de Datos en BI

Aspecto	Detalle
Resultado de aprendizaje	CT 12.2 RA5, RA1 — Técnicas de visualización y conceptos de BI
Objetivo de la parte	Construir un tablero ejecutivo en Power BI con medidas DAX y complementarlo con visualizaciones en Python, comunicando insights mediante storytelling de datos.
Herramientas	Python (notebook) + Power BI (modelo, DAX y tablero)

8.1 Pasos en Power BI

1. **Definir KPIs y preguntas de negocio** (ventas totales, margen, ticket promedio, crecimiento mensual, top categorías/tiendas).
2. **Crear medidas DAX** para cada KPI, evitando columnas calculadas innecesarias.
3. **Diseñar el tablero** con páginas: (a) Resumen ejecutivo, (b) Ventas por categoría/producto, (c) Análisis geográfico por tienda/canal, (d) Tendencia temporal.
4. **Agregar interactividad** (segmentadores por fecha, categoría, canal y región; tooltips informativos).
5. **Aplicar buenas prácticas de visualización** (títulos claros, formato de números, jerarquía visual, evitar exceso de colores y elementos).

Ejemplo de medidas DAX:

```
Ventas Totales =  
    SUMX(Fact_Ventas, Fact_Ventas[Cantidad] * Fact_Ventas[PrecioUnitario] * (1 -  
    Fact_Ventas[Descuento]))  
  
Margen Bruto =  
    [Ventas Totales] - SUMX(Fact_Ventas, Fact_Ventas[Cantidad] *  
    RELATED(Dim_Producto[Costo]))  
  
Ticket Promedio =  
    DIVIDE([Ventas Totales], DISTINCTCOUNT(Fact_Ventas[IdVenta]))  
  
Ventas Mes Anterior =  
    CALCULATE([Ventas Totales], DATEADD(Dim_Tiempo[Fecha], -1, MONTH))  
  
Crecimiento % =  
    DIVIDE([Ventas Totales] - [Ventas Mes Anterior], [Ventas Mes Anterior])
```

8.2 Pasos en Python (notebook 02_visualizacion.ipynb)

1. **Generar visualizaciones analíticas** (evolución temporal, Pareto de productos, distribución por categoría, mapa de calor por mes y categoría).
2. **Usar matplotlib/seaborn/plotly** y exportar las figuras clave para el informe.
3. **Redactar la narrativa de insights** en celdas Markdown: qué muestra cada gráfico y qué decisión sugiere.

Ejemplo de visualización en Python:

```
import matplotlib.pyplot as plt
```

```
ventas_mes = (df.groupby(df["fecha"].dt.to_period("M"))["importe"]
               .sum().sort_index())
ventas_mes.index = ventas_mes.index.to_timestamp()

plt.figure(figsize=(9, 4))
plt.plot(ventas_mes.index, ventas_mes.values, marker="o")
plt.title("Evolución mensual de ventas – AndesMarket")
plt.xlabel("Mes"); plt.ylabel("Ventas (S/)")
plt.tight_layout()
plt.savefig("informe/img/ventas_mensuales.png", dpi=120)
```

8.3 Entregables de la Parte 2

- Tablero de Power BI con al menos cuatro páginas y medidas DAX documentadas.
- Notebook 02_visualizacion.ipynb con visualizaciones y narrativa de insights.
- Resumen de 5 a 8 hallazgos accionables con su recomendación de negocio.
- Prompts utilizados, registrados según el Anexo A.

9. Parte 3: Clasificación en BI

Aspecto	Detalle
Resultado de aprendizaje	CT 11.2 RA7, RA8 — Minería de datos y técnicas avanzadas
Objetivo de la parte	Construir y evaluar un modelo supervisado de clasificación para predecir el abandono de clientes del programa de fidelización (o propensión de compra).
Herramientas	Python (notebook) + Power BI (modelo, DAX y tablero)

9.1 Pasos en Python (notebook 03_clasificacion.ipynb)

1. **Definir el problema y la variable objetivo.** Por ejemplo, abandono = 1 si el cliente no compra en los últimos N meses; 0 en caso contrario.
2. **Construir la tabla analítica (feature engineering)** desde el datamart: antigüedad, frecuencia, monto acumulado, recencia, categorías compradas, uso de promociones.
3. **Realizar el análisis exploratorio** (balance de clases, correlaciones, valores atípicos).
4. **Dividir en entrenamiento y prueba** de forma estratificada (por ejemplo, 75/25).
5. **Entrenar y comparar modelos** (Regresión Logística, Árbol de Decisión y Random Forest).
6. **Evaluar con métricas apropiadas** (matriz de confusión, precisión, recall, F1 y ROC-AUC), considerando el desbalance.
7. **Interpretar el modelo** (importancia de variables) y traducirlo a acciones de retención.
8. **Exportar las predicciones** (cliente y probabilidad de abandono) a un CSV para Power BI.

Ejemplo en Python:

```
from sklearn.model_selection import train_test_split
from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import classification_report, roc_auc_score, confusion_matrix

X = df[features]
y = df["abandono"]

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.25, stratify=y, random_state=42)

modelo = RandomForestClassifier(
    n_estimators=200, random_state=42, class_weight="balanced")
modelo.fit(X_train, y_train)

y_pred = modelo.predict(X_test)
y_proba = modelo.predict_proba(X_test)[: , 1]

print(confusion_matrix(y_test, y_pred))
print(classification_report(y_test, y_pred))
print("ROC-AUC:", round(roc_auc_score(y_test, y_proba), 3))
```

9.2 Integración con Power BI

- Importar el CSV de predicciones y crear una página de «Riesgo de abandono» con segmentadores por nivel de riesgo.
- Mostrar el número de clientes en riesgo, su valor asociado y las variables más influyentes.

9.3 Entregables de la Parte 3

- Notebook 03_clasificacion.ipynb con EDA, comparación de modelos, métricas e interpretación.
- Tabla de predicciones y página de Power BI de riesgo de abandono.
- Recomendaciones de retención basadas en el modelo y prompts registrados (Anexo A).

10. Parte 4: Segmentación en BI

Aspecto	Detalle
Resultado de aprendizaje	CT 11.2 RA7, RA8 — Minería de datos y técnicas avanzadas
Objetivo de la parte	Segmentar la base de clientes mediante clustering (RFM + K-Means), perfilar cada segmento y proponer estrategias diferenciadas.
Herramientas	Python (notebook) + Power BI (modelo, DAX y tablero)

10.1 Pasos en Python (notebook 04_segmentacion.ipynb)

1. **Construir las variables RFM** (Recencia, Frecuencia y Monto) por cliente a partir del datamart.
2. **Escalar las variables** (estandarización) para que ninguna domine por su magnitud.
3. **Determinar el número óptimo de clusters** con el método del codo y el coeficiente de silueta.
4. **Aplicar K-Means** con el k elegido y semilla fija.
5. **Perfilar cada segmento** (tamaño, RFM promedio, categorías preferidas, ticket).
6. **Nombrar los segmentos** (p. ej., «Campeones», «Leales», «En riesgo», «Nuevos») y proponer estrategias.
7. **Exportar la asignación cliente–segmento** a un CSV para Power BI.

Ejemplo en Python:

```
from sklearn.preprocessing import StandardScaler
from sklearn.cluster import KMeans
from sklearn.metrics import silhouette_score

rfm = clientes[["recencia", "frecuencia", "monto"]]
X = StandardScaler().fit_transform(rfm)

inercias, siluetas = [], []
for k in range(2, 11):
    km = KMeans(n_clusters=k, n_init=10, random_state=42).fit(X)
    inercias.append(km.inertia_)
    siluetas.append(silhouette_score(X, km.labels_))

k_optimo = 4 # justificar con codo y silueta
modelo = KMeans(n_clusters=k_optimo, n_init=10, random_state=42)
clientes["segmento"] = modelo.fit_predict(X)

perfil = clientes.groupby("segmento")[["recencia", "frecuencia", "monto"]].mean()
print(perfil)
```

10.2 Integración con Power BI

- Importar la asignación de segmentos y crear una página de «Segmentación de clientes».
- Mostrar el tamaño de cada segmento, su aporte a las ventas y su perfil RFM.

10.3 Entregables de la Parte 4

- Notebook 04_segmentacion.ipynb con justificación del número de clusters y perfilamiento.
- Tabla de segmentos, página de Power BI y estrategias por segmento.
- Prompts registrados (Anexo A).

11. Parte 5: Asociación en BI

Aspecto	Detalle
Resultado de aprendizaje	CT 11.2 RA7, RA8 — Minería de datos y técnicas avanzadas
Objetivo de la parte	Descubrir reglas de asociación (análisis de canasta de mercado) para identificar productos que se compran juntos y diseñar promociones cruzadas.
Herramientas	Python (notebook) + Power BI (modelo, DAX y tablero)

11.1 Pasos en Python (notebook 05_asociacion.ipynb)

1. **Preparar las transacciones** agrupando los productos por boleta (id_venta) en formato de canasta.
2. **Codificar las transacciones** a una matriz booleana (one-hot por producto o categoría).
3. **Aplicar Apriori o FP-Growth** para obtener itemsets frecuentes con un soporte mínimo razonable.
4. **Generar reglas de asociación** y calcular soporte, confianza y lift.
5. **Filtrar e interpretar** las reglas con lift > 1 y confianza alta, descartando las triviales.
6. **Traducir a acciones** (ubicación de productos, paquetes, promociones cruzadas, recomendaciones).

Ejemplo en Python (mlxtend):

```
from mlxtend.preprocessing import TransactionEncoder
from mlxtend.frequent_patterns import apriori, association_rules

transacciones = df.groupby("id_venta")["producto"].apply(list).tolist()

te = TransactionEncoder()
matriz = te.fit_transform(transacciones)
basket = pd.DataFrame(matriz, columns=te.columns_)

frecuentes = apriori(basket, min_support=0.01, use_colnames=True)
reglas = association_rules(frecuentes, metric="lift", min_threshold=1.2)
reglas = reglas.sort_values("lift", ascending=False)

print(reglas[["antecedents", "consequents", "support", "confidence", "lift"]].head(10))
```

11.2 Integración con Power BI

- Importar la tabla de reglas y crear una página de «Canasta de mercado» con las principales reglas y su lift.
- Permitir filtrar por categoría para explorar oportunidades de venta cruzada.

11.3 Entregables de la Parte 5

- Notebook 05_asociacion.ipynb con itemsets frecuentes y reglas interpretadas.
- Tabla de reglas priorizadas, página de Power BI y propuestas de promociones cruzadas.
- Prompts registrados (Anexo A).

12. Parte 6: Regresión en BI

Aspecto	Detalle
Resultado de aprendizaje	CT 11.2 RA7, RA8, RA6 — Minería de datos, técnicas avanzadas y tendencias de Big Data en BI
Objetivo de la parte	Construir y evaluar un modelo de regresión para pronosticar la venta/demanda y apoyar la planificación de inventario y campañas.
Herramientas	Python (notebook) + Power BI (modelo, DAX y tablero)

12.1 Pasos en Python (notebook 06_regresion.ipynb)

1. **Definir la variable objetivo** (p. ej., ventas diarias o semanales agregadas, o demanda por categoría).
2. **Construir variables predictoras** (componentes temporales, estacionalidad, indicador de promoción, feriados, rezagos).
3. **Dividir respetando el orden temporal** (entrenar con el pasado y validar con el periodo más reciente).
4. **Entrenar y comparar modelos** (Regresión Lineal, Random Forest y Gradient Boosting).
5. **Evaluar con métricas de regresión** (MAE, RMSE, MAPE y R^2).
6. **Interpretar y pronosticar** el periodo siguiente, y discutir el error en términos de negocio.
7. **Exportar real vs. pronóstico** a un CSV para Power BI.

Ejemplo en Python:

```
import numpy as np
from sklearn.ensemble import GradientBoostingRegressor
from sklearn.metrics import mean_absolute_error, mean_squared_error, r2_score

corte = int(len(X) * 0.8) # respeta el orden temporal
X_train, X_test = X.iloc[:corte], X.iloc[corte:]
y_train, y_test = y.iloc[:corte], y.iloc[corte:]

modelo = GradientBoostingRegressor(random_state=42)
modelo.fit(X_train, y_train)
pred = modelo.predict(X_test)

mae = mean_absolute_error(y_test, pred)
rmse = np.sqrt(mean_squared_error(y_test, pred))
mape = np.mean(np.abs((y_test - pred) / y_test)) * 100
print(f"MAE={mae:.2f} RMSE={rmse:.2f} MAPE={mape:.2f}% R2={r2_score(y_test, pred):.3f}")
```

12.2 Integración con Power BI

- Importar la tabla real vs. pronóstico y crear una página de «Pronóstico de demanda».
- Mostrar la curva real frente a la pronosticada y el error (MAPE) como KPI.

12.3 Entregables de la Parte 6

- Notebook 06_regresion.ipynb con comparación de modelos, métricas e interpretación de negocio.
- Tabla real vs. pronóstico, página de Power BI y recomendaciones de planificación.
- Prompts registrados (Anexo A).

13. Documentación de prompts (ingeniería de prompts)

El uso de asistentes de IA está **permitido y fomentado** como apoyo para estructurar el proyecto, generar los datos sintéticos, depurar código y redactar. Sin embargo, su uso debe ser **transparente y reproducible**: el equipo debe registrar los prompts que efectivamente ayudaron a estructurar y resolver el proyecto. Este registro es obligatorio y se evalúa.

Qué debe registrarse:

- Los prompts que definieron el caso de negocio y el modelo dimensional.
- **Los prompts de generación de datos sintéticos**, con el detalle de volúmenes, distribuciones y problemas de calidad introducidos (ver Anexo B).
- Los prompts que apoyaron cada técnica de minería (clasificación, segmentación, asociación y regresión).
- Para cada prompt: su objetivo, la herramienta/modelo, el resultado obtenido y los ajustes que el equipo realizó.

Principio rector. La IA es una herramienta de apoyo; el equipo es responsable de comprender, verificar y justificar cada resultado. Copiar resultados sin entenderlos se penaliza en la sustentación.

La plantilla de registro se encuentra en el **Anexo A** y los prompts de generación de datos, en el **Anexo B**.

14. Entregables y formato de entrega

14.1 Lista de entregables (entrega final)

Entregable	Descripción
Repositorio Git	Estructura completa de la sección 5, con commits de todos los integrantes.
6 notebooks de Python	Uno por parte, más el notebook de generación de datos (00).
Archivo Power BI (.pbix)	Modelo dimensional, medidas DAX y todas las páginas de tableros.
Datos sintéticos	Datos crudos (raw) y procesados (processed), reproducibles con semilla.
Anexo de prompts	Registro de prompts (Anexo A) y prompts de generación de datos (Anexo B).
Informe consolidado (PDF)	Documento integrador según la estructura del Anexo C.
Tabla de contribución	Aporte por integrante (porcentaje y tareas), firmada por el equipo.
Sustentación	Presentación oral con apoyo de Power BI y notebooks.

14.2 Formato del documento Word/PDF del informe

- Fuente Arial; documento en blanco y negro; tablas con fondo blanco, sin sombreados ni colores de relleno.
- Encabezado con: «UNMSM - FISI - E.P. Ingeniería de Software», el nombre de la asignatura y la indicación de que corresponde al Proyecto Grupal.
- Pie de página con «Prof. Juan Gamarra Moreno» y la numeración con el formato «Pág X de Y».
- Carátula con datos del equipo e integrantes; índice; y citación de fuentes cuando corresponda.

14.3 Nomenclatura y reglas de entrega

- Nombres de archivo sin tildes ni espacios (usar guiones bajos).
- Los notebooks deben entregarse ejecutados (con salidas visibles) y volver a ejecutarse sin errores.
- El .pbix debe abrir correctamente y reflejar los datos procesados.
- La entrega se realiza por el Aula Virtual en la fecha indicada; no se aceptan archivos que no abran o no ejecuten.

15. Rúbricas de evaluación

15.1 Estructura de calificación

La nota del Proyecto Grupal (PG) se obtiene combinando el promedio ponderado de las seis partes con una rúbrica transversal, según:

$$PG = 0.80 \times (\text{Promedio ponderado de las 6 partes}) + 0.20 \times (\text{Rúbrica transversal})$$

Cada parte y la rúbrica transversal se califican en escala vigesimal (0 a 20).

Los pesos de cada parte dentro del promedio ponderado son:

Parte	Producto	Peso
Parte 1	Datamart analítico	20%
Parte 2	Visualización de datos	15%
Parte 3	Clasificación	16%
Parte 4	Segmentación	16%
Parte 5	Asociación	16%
Parte 6	Regresión	17%
	Total	100%

15.2 Escala de niveles de desempeño

Cada criterio de cada parte vale 4 puntos (5 criterios = 20 puntos por parte). El puntaje de cada criterio se asigna según el nivel alcanzado:

Nivel	Rango del criterio	Significado
Logrado	4 (100%–85%)	Cumple plenamente y con calidad lo solicitado.
En proceso	2–3 (84%–50%)	Cumple parcialmente; con omisiones o errores subsanables.
En inicio	1 (49%–25%)	Cumplimiento mínimo o con errores importantes.
No evidenciado	0	No se presenta o no es funcional.

15.3 Rúbrica de la Parte 1 — Datamart analítico

Criterio (puntaje)	Logrado	En proceso	En inicio
Ingeniería de datos / ETL (4)	ETL estandariza fechas, normaliza categorías, elimina duplicados, trata nulos y valida integridad; reporta calidad antes/después.	Realiza la limpieza principal pero omite alguna validación o el reporte de calidad.	Limpieza incompleta o sin evidencia del antes/después.
Modelo dimensional (4)	Esquema estrella correcto: grano definido, dimensiones y hechos bien identificados, métricas derivadas correctas.	Modelo con grano, dimensión o medida imprecisa.	Modelo plano o relaciones conceptualmente incorrectas.

Criterio (puntaje)	Logrado	En proceso	En inicio
Integración con Power BI (4)	Relaciones uno-a-muchos correctas, calendario marcado, claves ocultas; modelo navegable.	Relaciones presentes con errores menores de cardinalidad o dirección.	Relaciones faltantes o modelo no funcional.
Diccionario y valor de negocio (4)	Diccionario de datos completo y diagrama claro; el datamart responde a las preguntas de negocio.	Diccionario o diagrama incompletos.	Sin diccionario ni diagrama útiles.
Documentación y prompts (4)	Notebook documentado y prompts registrados (Anexo A), incluyendo la generación de datos.	Documentación o registro de prompts parcial.	Sin documentación ni registro de prompts.

15.4 Rúbrica de la Parte 2 — Visualización de datos

Criterio (puntaje)	Logrado	En proceso	En inicio
Medidas DAX (4)	Medidas correctas y eficientes (ventas, margen, ticket, crecimiento) sin columnas calculadas innecesarias.	Medidas mayormente correctas con algún error o redundancia.	Medidas incorrectas o ausentes.
Diseño del tablero (4)	Tablero con ≥ 4 páginas, jerarquía visual clara, formato adecuado y buenas prácticas.	Tablero funcional pero con problemas de claridad o formato.	Tablero incompleto o confuso.
Interactividad (4)	Segmentadores y tooltips útiles; navegación coherente entre páginas.	Interactividad básica con limitaciones.	Sin interactividad significativa.
Storytelling e insights (4)	5–8 insights accionables con recomendación de negocio, sustentados en los datos.	Insights presentes pero poco accionables o sin sustento claro.	Sin insights o meramente descriptivos.
Visualización en Python y prompts (4)	Notebook con visualizaciones pertinentes, narrativa y prompts registrados (Anexo A).	Visualizaciones o registro de prompts parciales.	Sin visualizaciones en Python ni registro.

15.5 Rúbrica de la Parte 3 — Clasificación

Criterio (puntaje)	Logrado	En proceso	En inicio
Definición y datos (4)	Problema y variable objetivo bien definidos; tabla analítica con feature engineering desde el datamart.	Definición o features con limitaciones.	Problema mal definido o sin features adecuadas.
Modelado (4)	Compara ≥ 3 modelos con división estratificada y maneja el desbalance.	Entrena modelos pero con comparación o validación débil.	Un solo modelo sin validación adecuada.
Evaluación (4)	Usa matriz de confusión, precisión, recall, F1 y ROC-AUC e interpreta correctamente.	Evalúa con métricas incompletas o interpretación parcial.	Evaluación insuficiente o mal interpretada.
Interpretación y Power BI (4)	Importancia de variables, predicciones llevadas a Power BI y acciones de retención.	Interpretación o integración con Power BI parcial.	Sin interpretación accionable ni integración.
Documentación y prompts (4)	Notebook documentado y prompts registrados (Anexo A).	Documentación o prompts parciales.	Sin documentación ni prompts.

15.6 Rúbrica de la Parte 4 — Segmentación

Criterio (puntaje)	Logrado	En proceso	En inicio
Variables RFM (4)	Recencia, Frecuencia y Monto correctamente calculadas y escaladas.	RFM con errores menores o sin escalamiento.	RFM incorrectas o ausentes.
Selección de k (4)	Número de clusters justificado con codo y silueta.	Justificación parcial (solo un método).	k elegido sin justificación.
Clustering y perfilamiento (4)	K-Means aplicado correctamente; segmentos perfilados (tamaño, RFM, preferencias).	Perfilamiento incompleto.	Clustering sin perfilamiento útil.
Estrategias y Power BI (4)	Estrategias diferenciadas por segmento y página de Power BI con su aporte a ventas.	Estrategias genéricas o integración parcial.	Sin estrategias ni integración.
Documentación y prompts (4)	Notebook documentado y prompts registrados (Anexo A).	Documentación o prompts parciales.	Sin documentación ni prompts.

15.7 Rúbrica de la Parte 5 — Asociación

Criterio (puntaje)	Logrado	En proceso	En inicio
Preparación de transacciones (4)	Transacciones por boleta correctamente construidas y codificadas (one-hot).	Preparación con errores menores.	Transacciones mal construidas.
Itemsets y reglas (4)	Apriori/FP-Growth con soporte adecuado; reglas con soporte, confianza y lift.	Reglas generadas con parámetros poco justificados.	Reglas incorrectas o ausentes.
Interpretación (4)	Filtra reglas relevantes (lift > 1) y descarta triviales; interpreta correctamente.	Interpretación parcial o incluye reglas triviales.	Sin interpretación válida.
Acciones y Power BI (4)	Propuestas de venta cruzada y página de Power BI con las reglas principales.	Propuestas genéricas o integración parcial.	Sin propuestas ni integración.
Documentación y prompts (4)	Notebook documentado y prompts registrados (Anexo A).	Documentación o prompts parciales.	Sin documentación ni prompts.

15.8 Rúbrica de la Parte 6 — Regresión

Criterio (puntaje)	Logrado	En proceso	En inicio
Variable objetivo y features (4)	Objetivo bien definido y variables predictoras pertinentes (temporales, estacionalidad, promociones, rezagos).	Features con limitaciones.	Objetivo o features inadecuados.
Validación temporal (4)	División que respeta el orden temporal (pasado/entrena, reciente/valida).	División con fugas temporales menores.	División aleatoria que ignora el tiempo.
Modelado y métricas (4)	Compara ≥ 3 modelos y evalúa con MAE, RMSE, MAPE y R^2 .	Comparación o métricas incompletas.	Un modelo sin métricas adecuadas.
Pronóstico y Power BI (4)	Pronóstico interpretado en términos de negocio y página de Power BI real vs. pronóstico.	Pronóstico o integración parcial.	Sin pronóstico útil ni integración.
Documentación y prompts (4)	Notebook documentado y prompts registrados (Anexo A).	Documentación o prompts parciales.	Sin documentación ni prompts.

15.9 Rúbrica transversal (20%)

Criterio (puntaje)	Logrado	En proceso	En inicio
Informe consolidado (4)	Informe completo, bien redactado y con el formato institucional (Anexo C).	Informe con vacíos de contenido o formato.	Informe incompleto o sin formato.
Datos sintéticos y prompts (4)	Datos reproducibles (semilla) con problemas de calidad documentados y prompts de generación detallados (Anexo B).	Reproducibilidad o documentación parcial.	Datos no reproducibles o sin documentar.
Sustentación y dominio (4)	Todos los integrantes dominan el conjunto y responden con solvencia.	Dominio desigual entre integrantes.	Dominio insuficiente o dependencia de notas.
Trabajo colaborativo (4)	Roles claros, repositorio Git con aportes de todos y bitácora de trabajo.	Colaboración con evidencias parciales.	Aporte desigual o sin evidencia de colaboración.
Integridad y ética (4)	Uso de IA declarado, código comprendido y consideraciones éticas de datos.	Declaración o reflexión ética parcial.	Sin declaración o con indicios de copia no comprendida.

16. Cuadro de autoevaluación

Antes de entregar, el equipo debe completar los siguientes cuadros para verificar **cuánto está cumpliendo con las rúbricas**. La autoevaluación es obligatoria, se entrega con el proyecto y se contrasta con la evaluación del docente.

16.1 Autoevaluación por componente

Asigne un autopuntaje (0–20) a cada parte y a la rúbrica transversal, indicando la evidencia (archivo o sección del informe). El PG estimado aplica la fórmula de la sección 15.1.

Componente	Punt. máx.	Peso en PG	Autopuntaje (0–20)	Evidencia (archivo / sección)
Parte 1 — Datamart	20	20%		
Parte 2 — Visualización	20	15%		
Parte 3 — Clasificación	20	16%		
Parte 4 — Segmentación	20	16%		
Parte 5 — Asociación	20	16%		
Parte 6 — Regresión	20	17%		
Promedio ponderado de partes	20	80%		
Rúbrica transversal	20	20%		
PG estimado	20	100%		

16.2 Lista de verificación detallada del cumplimiento

Para cada criterio, marque si está cumplido (Sí / Parcial / No), indique la evidencia, la brecha detectada y la acción de mejora. Replique esta lógica por cada parte cuando lo requiera.

Criterio a verificar	Sí / Parcial / No	Evidencia	Brecha	Acción de mejora
Datos sintéticos reproducibles (semilla) y documentados				
ETL corrige los 7 problemas de calidad y reporta antes/después				
Esquema estrella correcto y relaciones válidas en Power BI				
Medidas DAX correctas y tablero con ≥4 páginas				
Storytelling con ≥5 insights accionables				
Clasificación: comparación de modelos + métricas (incl. ROC-AUC)				
Clasificación: interpretación y predicciones en Power BI				
Segmentación: k justificado +				

Criterio a verificar	Sí / Parcial / No	Evidencia	Brecha	Acción de mejora
perfilamiento + estrategias				
Asociación: reglas con soporte/confianza/lift interpretadas				
Asociación: propuestas de venta cruzada				
Regresión: validación temporal + MAE/RMSE/MAPE/R ² + pronóstico				
Notebooks ejecutan de principio a fin sin errores				
Repositorio Git con commits de todos los integrantes				
Registro de prompts (Anexo A) e incluye generación de datos (Anexo B)				
Informe consolidado con la estructura del Anexo C				
Tabla de contribución por integrante				
Sustentación: cada integrante domina el conjunto				
Uso ético de IA declarado y código comprendido				

17. Integridad académica y uso responsable de IA

- **Datos ficticios.** Está prohibido usar datos reales de empresas o personas. Todos los datos son sintéticos y generados por el equipo.
- **Transparencia con la IA.** Se permite el uso de asistentes de IA, pero debe declararse y documentarse mediante el registro de prompts. El equipo debe comprender y poder explicar todo el código y los resultados.
- **Autoría.** El plagio entre equipos, la copia de soluciones ajenas o la presentación de resultados no comprendidos conllevan sanción conforme al reglamento.
- **Reproducibilidad.** La calificación valora que cualquier persona pueda regenerar los datos y reproducir los resultados ejecutando los notebooks en orden.
- **Ética de datos.** El informe debe incluir una breve reflexión sobre privacidad, sesgo y uso responsable de los modelos en un contexto empresarial real.

18. Anexos

Anexo A — Plantilla de registro de prompts

Complete una fila por cada prompt relevante. El registro completo se entrega en prompts/registro_prompts.md.

N°	Parte	Objetivo del prompt	Herramienta / Modelo	Resultado / Uso	Ajustes del equipo
1	Datos	Diseñar el esquema dimensional del caso	Asistente IA	Borrador del modelo estrella revisado	Se ajustó el grano y se añadió Dim_Promoción
2	Datos	Generar datos sintéticos con problemas de calidad	Asistente IA + Python	Script de generación reproducible	Se calibraron volúmenes y % de nulos
...					

Anexo B — Prompts de generación de datos sintéticos

B.1 Prompt para diseñar el caso y el modelo dimensional.

Actúa como arquitecto de Business Intelligence. Diseña el modelo dimensional (esquema estrella) para una cadena ficticia de retail omnicanal en Perú llamada "AndesMarket S.A.C." que opera supermercados físicos y un canal online, con un programa de fidelización. El modelo debe permitir analizar ventas, predecir abandono de clientes, segmentar clientes, descubrir reglas de asociación y pronosticar la demanda.

Entrega:

- 1) El proceso de negocio y el grano de la tabla de hechos.
- 2) Las dimensiones (Cliente, Producto, Tienda, Tiempo, Promoción) con sus campos.
- 3) La tabla de hechos Fact_Ventas con sus métricas (cantidad, precio, descuento, importe, costo, margen).
- 4) Un diagrama textual del esquema estrella y un diccionario de datos.

B.2 Prompt maestro de generación de datos sintéticos (detallado).

Este es el prompt central exigido por el proyecto: especifica volúmenes, distribuciones, reglas de realismo y los problemas de calidad introducidos a propósito. Debe producir un script de Python reproducible.

Actúa como ingeniero de datos. Genera un script de Python (usando pandas, numpy y faker, con locale "es_ES") que cree datos sintéticos REPRODUCIBLES para la empresa ficticia "AndesMarket S.A.C." Fija la semilla 42 en numpy y faker.

VOLÚMENES (referenciales):

- Dim_Cliente: 5000 clientes (id_cliente, nombre, sexo, fecha_nacimiento, distrito, fecha_alta, segmento_programa)
- Dim_Producto: 500 productos (id_producto, nombre, categoria, subcategoria, marca, precio_lista, costo)
- Dim_Tienda: 15 tiendas (id_tienda, nombre, canal[fisico/online], region, ciudad)
- Dim_Tiempo: 730 días (2 años) (fecha, dia, mes, trimestre, anio, dia_semana, es_feriado)
- Dim_Promocion: 40 promociones (id_promocion, nombre, tipo, descuento_pct, fecha_inicio, fecha_fin)
- Fact_Ventas: 60000 líneas de venta (id_venta, fecha, id_cliente, id_producto,

id_tienda, id_promocion, cantidad, precio_unitario, descuento)

REGLAS DE REALISMO:

- Estacionalidad: mayor volumen de ventas en julio y diciembre; menor en meses bajos.
- Concentración tipo Pareto: ~20% de productos genera ~80% de las ventas; pocos clientes muy frecuentes y muchos esporádicos.
- precio_unitario varía +/- alrededor de precio_lista; el descuento aplica solo si la venta cae dentro de una promoción vigente.
- Afinidad de canasta: algunas categorías tienden a comprarse juntas (p. ej., snacks + bebidas) para que existan reglas con lift > 1.
- Abandono (churn): ~20-25% de clientes deja de comprar luego de cierto periodo; agrega una columna/lógica que permita etiquetar abandono para clasificación.

PROBLEMAS DE CALIDAD A INTRODUCIR (en los archivos data/raw):

- Fechas en formatos MIXTOS: "dd/mm/aaaa", "aaaa-mm-dd" y algunas como texto.
- Valores faltantes (~3-8%) en descuento, distrito y categoría.
- Duplicar ~1-2% de las líneas de venta.
- Texto inconsistente en categoría: mayúsculas/minúsculas y espacios sobrantes.
- Errores de tipeo: variantes como "Lacteos", "lácteos", "LACTEOS".
- Outliers: algunas cantidades y precios extremos poco realistas.
- ~0.5% de id_producto en Fact_Ventas que NO existen en Dim_Producto (claves huérfanas).

SALIDA:

- Guarda cada tabla como CSV separado por ";" y codificación UTF-8 en data/raw/ (versión con problemas) y deja Dim_* limpias en data/processed/ cuando aplique.
- Imprime un resumen: número de filas por tabla, % de nulos por columna, número de duplicados y de claves huérfanas, para evidenciar el estado inicial de calidad.

B.3 Prompts de apoyo por técnica de minería.

[Clasificación] Actúa como científico de datos. A partir del datamart, construye la tabla analítica para predecir abandono de clientes (antigüedad, recencia, frecuencia, monto, categorías compradas, uso de promociones). Compara Regresión Logística, Árbol de Decisión y Random Forest con división estratificada 75/25 y semilla 42, maneja el desbalance y reporta matriz de confusión, precisión, recall, F1 y ROC-AUC. Explica la importancia de variables y propón acciones de retención.

[Segmentación] Calcula variables RFM por cliente, escálalas y determina el número de clusters con el método del codo y la silueta. Aplica K-Means (semilla 42), perfila cada segmento y propón estrategias diferenciadas.

[Asociación] Construye transacciones por boleta, aplica Apriori/FP-Growth con un soporte mínimo razonable, genera reglas con soporte, confianza y lift, filtra las relevantes (lift > 1) y propón promociones cruzadas.

[Regresión] Define la venta/demanda agregada como objetivo, crea variables temporales, de estacionalidad, de promoción y rezagos, divide respetando el orden temporal, compara Regresión Lineal, Random Forest y Gradient Boosting, y evalúa con MAE, RMSE, MAPE y R².

Anexo C — Estructura sugerida del informe consolidado

1. Carátula (con datos del equipo e integrantes) e índice.
2. Resumen ejecutivo del proyecto y de los principales hallazgos.
3. Descripción de la empresa ficticia, problemática y preguntas de negocio.

4. Generación de datos sintéticos: esquema, volúmenes, distribuciones y problemas de calidad.
5. Parte 1 — Datamart: modelo dimensional, ETL, diccionario y modelo en Power BI.
6. Parte 2 — Visualización: tablero, medidas DAX e insights.
7. Parte 3 — Clasificación: definición, modelos, evaluación e interpretación.
8. Parte 4 — Segmentación: RFM, clusters, perfiles y estrategias.
9. Parte 5 — Asociación: reglas y propuestas de venta cruzada.
10. Parte 6 — Regresión: pronóstico, métricas y recomendaciones.
11. Reflexión ética y de integridad; anexo de prompts (A y B).
12. Conclusiones, recomendaciones y tabla de contribución por integrante.

Anexo D — Lista de verificación final de entrega

- [] Repositorio Git con la estructura de la sección 5 y commits de todos los integrantes.
- [] Notebook 00 de generación de datos reproducible (semilla 42).
- [] Datos en data/raw (con problemas) y data/processed (limpios).
- [] Notebooks 01 a 06 ejecutados y re-ejecutables sin errores.
- [] Archivo AndesMarket.pbix con modelo, DAX y todas las páginas.
- [] Registro de prompts (Anexo A) y prompts de generación de datos (Anexo B).
- [] Informe consolidado en PDF con el formato institucional.
- [] Cuadros de autoevaluación (16.1 y 16.2) completados.
- [] Tabla de contribución por integrante, firmada.
- [] Preparada la sustentación con dominio individual de todo el proyecto.

— *Fin de las instrucciones del Proyecto Grupal* —