




Universidad Nacional Mayor de San Marcos

Facultad de Ingeniería de Sistemas e Informática

E.P. de Ingeniería de Software

Botica Los Andes

Asignatura: Inteligencia de negocios

Docente: Gamarra Moreno, Juan

Estudiantes:

- Cisneros Culaca, David
- Coronel Callupe, Giovanni
- Chavez Gave, Jose
- Patricio Julca, Vilberto
- Tataje Guzman, Kenner

Índice

1. Introducción.....	4
1.1. Descripción de la empresa.....	4
1.2. Problemática.....	4
1.3. Preguntas de negocio.....	5
2. Generación de datos sintéticos.....	5
2.1. Esquema.....	5
2.2. Volúmenes.....	6
2.3. Distribuciones.....	7
2.3.1. Estacionalidad.....	7
2.3.2. Concentración tipo Pareto en productos.....	8
2.3.3. Frecuencia de clientes.....	8
2.3.4. Abandono (Churn).....	9
2.3.5. Afinidad de canasta.....	9
2.3.6. Precio unitario y descuentos.....	10
2.4. Problemas de calidad.....	10
2.4.1. Fechas en formatos mixtos.....	10
2.4.2. Valores faltantes.....	10
2.4.3. Texto inconsistente en categoría.....	11
2.4.4. Errores de tipeo en nombre de producto.....	11
2.4.5. Filas duplicadas en Fact_Ventas.....	11
2.4.6. Outliers.....	11
2.4.7. Claves huérfanas en Fact_Ventas.....	12
3. Datamart: modelo dimensional, ETL, diccionario y modelo en Power BI.....	12
3.1. Modelo dimensional.....	12
3.2. Diagrama del esquema estrella.....	13
3.3. ETL — Extracción, Transformación y Carga.....	14
3.3.1. Carga inicial.....	14
3.3.2. Reporte de calidad inicial.....	14
3.3.3. Transformaciones aplicadas.....	15
3.3.4. Resultado final.....	16
3.4. Diccionario de Datos.....	17
3.5. Captura del modelo en Power BI.....	18
4. Visualización de datos.....	19
4.1. Medidas DAX implementadas.....	19
4.2. Visualización.....	20
4.2.1. Evolución Temporal y Estacionalidad.....	21
4.2.2. Análisis de Concentración (Principio de Pareto).....	22
4.2.3. Mapa de Calor (Heatmap): Categorías vs. Meses.....	24
5. Clasificación en BI.....	25

UNMSM - FISl - E.P. Ingeniería de Software
Inteligencia de Negocios
Proyecto Grupal

5.1. Definición del problema y variable objetivo.....	25
5.2. Construcción de variables (feature engineering).....	25
5.3. Comparación de modelos.....	27
5.4. Elección del modelo final.....	28
5.5. Interpretación del modelo.....	28
5.6. Recomendaciones de retención.....	29
6. Segmentación en BI.....	30
6.1. Variables RFM.....	30
6.2. Clusters.....	31
6.3. Perfiles.....	32
6.4. Estrategias.....	33
7. Asociación en BI.....	34
7.1. Reglas de asociación.....	34
7.2. Venta cruzada.....	35
8. Regresión.....	36
8.1. Objetivo.....	36
8.2. Metodología.....	36
8.3. Resultados.....	37
8.4. Importancia de predictores (Permutation Importance).....	37
8.5. Pronóstico semanal.....	38
8.7. Recomendaciones de negocio.....	40
8.7.1. Recomendación de Planificación.....	40
9. Reflexión ética y de integridad.....	41
10. Conclusiones.....	42
11. Cuadro de autoevaluación.....	44
11.1. Autoevaluación por componente.....	44
11.2. Lista de verificación.....	44

Resumen

El proyecto "LosAndes" para Botica Los Andes representa una solución de Inteligencia de Negocios (BI) que abarca desde la estructuración de datos hasta la aplicación de algoritmos de machine learning. El objetivo principal ha sido transformar datos transaccionales en conocimiento accionable, facilitando la toma de decisiones estratégicas basadas en evidencia empírica. A través de un enfoque estructurado en múltiples fases, se ha logrado diagnosticar la situación del negocio, predecir el comportamiento futuro de los clientes y descubrir patrones ocultos de consumo, utilizando herramientas como Python y Power BI.

Principales hallazgos

Se implementó un Datamart utilizando el esquema estrella y un proceso ETL que corrigió problemas de calidad de los datos, obteniendo una fuente confiable para el análisis. El análisis descriptivo identificó estacionalidad en las ventas y confirmó el principio de Pareto, evidenciando que un reducido grupo de categorías concentra la mayor parte de los ingresos.

En la predicción de fuga de clientes, el modelo Random Forest obtuvo el mejor desempeño (ROC-AUC = 0.862), determinando que la recencia de compra es el principal predictor del abandono, seguida por la edad, mientras que las variables demográficas tuvieron un impacto mínimo.

La segmentación mediante K-Means identificó seis clústeres de clientes, permitiendo definir estrategias de fidelización más específicas. Asimismo, el algoritmo Apriori descubrió asociaciones entre productos, facilitando acciones de venta cruzada, promociones y creación de paquetes comerciales.

Finalmente, para el pronóstico de la demanda, la Regresión Lineal fue el modelo más preciso (MAPE = 21.94%; $R^2 = 0.586$), proyectando ventas semanales superiores a S/ 52,000 y demostrando que la estacionalidad y las promociones son los factores con mayor influencia en las ventas.

1. Introducción

El presente proyecto desarrolla una solución integral de Inteligencia de Negocios orientada a transformar los datos transaccionales operativos en información estratégica y accionable para la botica farmacéutica nacional llamada "Los Andes".

1.1. Descripción de la empresa

La cadena de boticas farmacéuticas de la empresa "Los Andes", cuenta con operaciones tanto en sucursales físicas como a través de un canal de comercio electrónico. Esta empresa se dedica a la venta minorista de diversas categorías, incluyendo medicamentos, cuidado personal, cuidado de la piel y fórmulas infantiles. Para conocer de cerca a sus consumidores, la botica cuenta con un programa de fidelización denominado "Club Andes", el cual permite identificar a los clientes más fieles y vincularlos con su historial de compras y promociones en productos.

1.2. Problemática

La botica "Los Andes" enfrenta una problemática crítica relacionada con la gestión de su información. Actualmente, los datos operativos se encuentran dispersos, presentan formatos inconsistentes y carecen de un proceso de validación, lo que obliga a la gerencia a tomar decisiones. La ausencia de un repositorio analítico centralizado impide a la empresa entender a profundidad el comportamiento de sus pacientes, lo que dificulta la identificación de los clientes con tratamientos crónicos que pueden abandonar la compra de los productos de la farmacia. Asimismo, la compañía carece de herramientas para anticipar la demanda, generando quiebres de stock en medicamentos críticos o excesos de inventario en otras categorías.

1.3. Preguntas de negocio

Para resolver dicha situación, la gerencia plantea una serie de preguntas de negocio para solucionar su problemática.

- ¿Cómo evolucionan las ventas y el margen por categoría (ej. medicamentos, cuidado personal), sucursal, canal (físico u online) y periodo?
- ¿Qué clientes del "Club Andes" tienen mayor probabilidad de abandonar el programa de fidelización o dejar de adquirir sus tratamientos?
- ¿Qué segmentos de clientes existen en la base de datos de la botica y cómo debería tratarse a cada uno?
- ¿Qué productos se compran juntos con frecuencia y qué promociones cruzadas conviene impulsar?
- ¿Cuál será la demanda o venta esperada para planificar el inventario de medicamentos y campañas comerciales?

2. Generación de datos sintéticos

Dado que "Botica Los Andes" es un caso de estudio ficticio, la base analítica de este proyecto reposa sobre un conjunto de datos sintéticos generados específicamente para simular su entorno operativo.

2.1. Esquema

Se adopta un modelo dimensional en estrella compuesto por cinco tablas de dimensión y una tabla de hechos. Todas las tablas se exportan como archivos CSV separados por punto y coma (;) en codificación UTF-8, disponibles en dos versiones:

- data/raw/ : versión con problemas de calidad introducidos a propósito.
- data/processed/ : versión limpia para validar el proceso de limpieza.

UNMSM - FISl - E.P. Ingeniería de Software
Inteligencia de Negocios
Proyecto Grupal

Tabla	Filas	Columnas clave
Dim_Cliente	5,000	id_cliente, nombre, sexo, fecha_nacimiento, distrito, fecha_alta, segmento_programa
Dim_Producto	500	id_producto, nombre, categoria, subcategoria, marca, precio_lista, costo
Dim_Tienda	15	id_tienda, nombre, canal, region, ciudad
Dim_Tiempo	730	fecha, dia, mes, trimestre, anio, dia_semana, es_feriado
Dim_Promocion	40	id_promocion, nombre, tipo, descuento_pct, fecha_inicio, fecha_fin
Fact_Ventas	~60,953	id_venta, fecha, id_cliente, id_producto, id_tienda, id_promocion, cantidad, precio_unitario, descuento

Las claves foráneas de Fact_Ventas referencian a cada dimensión por su campo id_*. La tabla Dim_Cliente en processed incluye tres columnas adicionales para modelado de abandono: fecha_ultima_compra, dias_desde_ultima_compra y churn.

2.2. Volúmenes

La siguiente tabla resume el número de filas generadas por tabla en cada capa:

Tabla	Filas (raw)	Filas (proc.)	Periodo
Dim_Cliente	5,000	5,000	—
Dim_Producto	500	500	—
Dim_Tienda	15	15	—

UNMSM - FISI - E.P. Ingeniería de Software
Inteligencia de Negocios
Proyecto Grupal

Dim_Tiempo	730	730	01/01/2024 – 31/12/2025
Dim_Promocion	40	40	—
Fact_Ventas	~60,953	—	01/01/2024 – 31/12/2025

Fact_Ventas se construye por canastas de compra, no línea por línea, con un tamaño promedio de 1.8 productos por visita. Eso equivale a aproximadamente 33,000 visitas distribuidas entre los 5,000 clientes durante los 730 días del periodo. Las ~953 filas extra en raw corresponden a los duplicados introducidos en el paso de calidad (~1.6% del total base).

2.3. Distribuciones

2.3.1. Estacionalidad

Se asigna un peso relativo por mes a cada día del calendario. Adicionalmente, los fines de semana reciben un incremento del 15% sobre el peso diario para simular mayor afluencia a tienda física.

Mes	Peso	Mes	Peso	Unidades vendidas (resultado)
Enero	1.00	Julio	1.80	28,564
Febrero	0.65	Agosto	1.00	—
Marzo	0.85	Septiembre	0.90	—
Abril	0.65	Octubre	0.95	7,459 (mínimo)
Mayo	0.95	Noviembre	1.10	—
Junio	1.05	Diciembre	1.85	26,951

Temporada alta. Resultado validado: julio acumuló 28,564 unidades y diciembre 26,951, frente a 7,459 en abril (mes más bajo).

2.3.2. Concentración tipo Pareto en productos

Se utiliza un esquema de dos niveles en lugar de una distribución Pareto pura (que generaba que un único producto concentrará hasta el 28% de las ventas, un resultado poco realista):

- Top 20% de productos ("estrella"): peso uniforme entre 3 y 7.
- Restante 80% de productos ("regular"): peso uniforme entre 0.2 y 0.8.

Resultado validado: el top 20% de productos generó el 84.4% de las unidades vendidas. El producto más vendido individualmente representó el 1.96% del total.

2.3.3. Frecuencia de clientes

Se aplica un esquema de tres niveles para evitar concentraciones irreales (el esquema Pareto puro llegó a asignar 2,126 compras a un solo cliente en 2 años):

Nivel	% de clientes	Peso de frecuencia asignado	Resultado
Muy frecuente	5%	Uniforme 8 – 16	Max 112 líneas
Frecuente	20%	Uniforme 2 – 6	—
Esporádico	75%	Uniforme 0.05 – 1.2	328 sin compra

El top 10% de clientes generó el 46% de las líneas de venta. 328 clientes no registraron ninguna compra en el período (clientes recién dados de alta o de muy baja frecuencia).

2.3.4. Abandono (Churn)

El 22.5% de los clientes fue marcado como churn durante la generación (probabilidad $p = 0.225$). A estos clientes se les asignó una fecha de corte de actividad aleatoria dentro del periodo, después de la cual no se les generaron compras. Resultado validado: 21.4% de clientes etiquetados como churn = 1, dentro del rango objetivo de 20–25%.

La etiqueta de abandono (churn) se basa en la lógica real de generación —la ventana de actividad cerrada—, no en un umbral de "días sin comprar", ya que dicho umbral no es confiable cuando existen muchos clientes esporádicos por naturaleza. Las columnas disponibles en Dim_Cliente (processed) para modelado son:

- fecha_ultima_compra — última fecha de compra registrada en Fact_Ventas.
- dias_desde_ultima_compra — diferencia en días respecto al 31/12/2025.
- churn — variable target binaria (0 = activo, 1 = abandono).

2.3.5. Afinidad de canasta

Con una probabilidad del 45%, el segundo y tercer ítem de cada canasta se elige de una categoría con afinidad declarada respecto al primer ítem. Se definieron cuatro pares de afinidad:

Par de categorías	Support	Confidence	Lift
Medicamentos → Suplementos y Vitaminas	0.079	0.265	1.38
Cuidado del Bebé → Cuidado Personal	0.094	0.391	1.37
Dermocosmética → Cuidado Personal	0.076	0.414	1.45
Equipos Médicos → Medicamentos	0.100	0.391	1.31

Todos los pares presentan lift > 1, confirmando que las categorías afines se compran juntas con mayor frecuencia de la esperada al azar. Estas reglas son directamente utilizables en un análisis de Market Basket con el algoritmo Apriori (mlxtend).

2.3.6. Precio unitario y descuentos

- precio_unitario varía $\pm 5\%$ alrededor del precio_lista (factor uniform(0.95, 1.06)).
- El descuento aplica solo si la venta cae dentro de una promoción vigente Y con probabilidad adicional del 60%, produciendo nulos legítimos en id_promocion (lógica de negocio, no error de calidad).
- Las 40 promociones tienen duración aleatoria de 5 a 30 días y descuentos de 5%, 10%, 15%, 20%, 25% o 30%.

2.4. Problemas de calidad

Los problemas se introducen únicamente en los archivos de data/raw/. La versión data/processed/ sirve para validar los scripts de limpieza. El resumen de calidad se imprime automáticamente al ejecutar el script generador.

2.4.1. Fechas en formatos mixtos

Afecta a fecha_nacimiento y fecha_alta en Dim_Cliente, y a fecha en Fact_Ventas. Cada valor se convierte a uno de tres formatos según distribución aleatoria:

- dd/mm/aaaa → 45% de los casos.
- aaaa-mm-dd → 45% de los casos.
- Texto libre en español → 10% de los casos (ejemplo: "19 de noviembre de 2024").

2.4.2. Valores faltantes

Columna	Tabla	% de nulos real
---------	-------	-----------------

UNMSM - FISI - E.P. Ingeniería de Software
Inteligencia de Negocios
Proyecto Grupal

distrito	Dim_Cliente	6.44% (objetivo 3–8%)
categoría	Dim_Producto	6.20% (objetivo 3–8%)
descuento	Fact_Ventas	~5.40% (objetivo 3–8%)

2.4.3. Texto inconsistente en categoría

Al 45% de las filas no nulas de Dim_Producto se les aplica uno de cuatro estilos de "suciedad":

- Todo mayúsculas: MEDICAMENTOS
- Todo minúsculas: medicamentos
- Espacios sobrantes al inicio y fin: " Medicamentos "
- Mayúsculas con espacios: " MEDICAMENTOS "

2.4.4. Errores de tipeo en nombre de producto

Al 18% de los productos en Dim_Producto se les aplica una variante de escritura:

- Todo mayúsculas: IBUPROFENO 400MG
- Todo minúsculas: ibuprofeno 400mg
- Eliminación de tildes: Acido Acetilsalicilico 100mg (en lugar de Ácido Acetilsalicílico 100mg)

2.4.5. Filas duplicadas en Fact_Ventas

Entre el 1% y el 2% de las líneas de venta base se duplican de forma aleatoria y se mezclan en el dataset para que no queden agrupadas al final. Resultado: 953 filas duplicadas (~1.6%), detectables con `df.duplicated()`.

2.4.6. Outliers

- cantidad: ~0.4% de filas con valores extremos: 150, 200, 500 o 999 unidades.

- precio_unitario: ~0.4% de filas con valores extremos: S/ 0.01, S/ 0.50, S/ 1,999.00 o S/ 4,999.00.

2.4.7. Claves huérfanas en Fact_Ventas

Al 0.5% de las líneas de Fact_Ventas se les reemplaza el id_producto por un valor ficticio que no existe en Dim_Producto (rango 1,501 – 1,599). Resultado: 300 claves huérfanas, detectables con un merge anti-join entre Fact_Ventas y Dim_Producto.

3. Datamart: modelo dimensional, ETL, diccionario y modelo en Power BI

La construcción del modelo dimensional de "Botica Los Andes" siguiendo el esquema estrella, la base analítica de este proyecto reposa sobre un conjunto de datos sintéticos generados específicamente para simular su entorno operativo.

3.1. Modelo dimensional

Proceso de negocio

Venta minorista de productos farmacéuticos, cuidado personal, dermocosmética, suplementos, equipos médicos e insumos en una cadena de boticas con canal físico y online ("Botica Salud Total").

Grano

Línea de venta de un producto dentro de una boleta/compra. Cada fila de Fact_Ventas representa un producto comprado en una transacción específica (id_venta + id_producto).

Tabla de hechos (Fact_Ventas):

Hecho	Filas
cantidad	Unidades vendidas del producto
precio_unitario	Precio aplicado en la venta

UNMSM - FISl - E.P. Ingeniería de Software
Inteligencia de Negocios
Proyecto Grupal

descuento	Monto de descuento en soles
importe	$(\text{cantidad} \times \text{precio_unitario}) - \text{descuento}$
costo	$\text{cantidad} \times \text{costo_unitario del producto}$
margen	$\text{importe} - \text{costo}$

Dimensiones:

Tabla	Descripción	Clave
Dim_Cliente	Datos del cliente	id_cliente
Dim_Producto	Catálogo de productos	id_producto
Dim_Tienda	Puntos de venta	id_tienda
Dim_Tiempo	Calendario (2 años)	fecha
Dim_Promocion	Ofertas vigentes	id_promocion

3.2. Diagrama del esquema estrella

Para el diagrama contamos con las 5 dimensiones (Cliente, Producto, Tienda, Tiempo, Promoción) conectadas a la tabla de hechos Fact_Ventas mediante sus claves foráneas. Fact_Ventas es el centro del modelo con métricas de cantidad, precio, descuento, importe, costo y margen.

UNMSM - FISI - E.P. Ingeniería de Software
Inteligencia de Negocios
Proyecto Grupal



3.3. ETL — Extracción, Transformación y Carga

3.3.1. Carga inicial

Se importaron 6 archivos CSV desde data/raw/ con los siguientes volúmenes:

Tabla	Filas
Dim_Cliente	5,000
Dim_Producto	500
Dim_Tienda	15
Dim_Tiempo	730
Dim_Promocion	40
Fact_Ventas	60,953

3.3.2. Reporte de calidad inicial

Nulos detectados:

UNMSM - FISI - E.P. Ingeniería de Software
Inteligencia de Negocios
Proyecto Grupal

Tabla	Columna	Nulos	Porcentaje (%)
Dim_Cliente	distrito	322	6.44%
Dim_Producto	categoria	31	6.20%
Fact_Ventas	id_promocion	36,761	60.31%
Fact_Ventas	descuento	3,269	5.36%

Duplicados:

953 filas duplicadas en Fact_Ventas.

Claves huérfanas:

305 registros en Fact_Ventas con id_producto sin referencia en Dim_Producto (0.50%).

3.3.3. Transformaciones aplicadas

Estandarización de fechas:

Las columnas fecha (Fact_Ventas), fecha_nacimiento y fecha_alta (Dim_Cliente) contenían 3 formatos distintos (ISO 2024-05-10, dd/mm/aaaa 10/05/2024, y texto en español 10 de mayo de 2024). Se implementó la función limpiar_fechas() que:

- Reemplaza nombres de meses en español por su número (ej: mayo en 05)
- Aplica máscaras separadas para formato ISO (%Y-%m-%d) y local (%d/%m/%Y)
- Resultado: 0 valores nulos en las 3 columnas de fecha

Normalización de categorías:

Se unificaron 35 variantes de categorías en Dim_Producto a 8 categorías estandarizadas mediante mapeo. Las 31 filas con categoría nula se asignaron a "Sin Categoría".

Tratamiento de nulos:

- **distrito (Dim_Cliente):** 322 nulos → "Sin Especificar"
- **descuento (Fact_Ventas):** 3,269 nulos → 0.0 (no hay descuento)
- **id_promocion (Fact_Ventas):** 36,761 nulos → no se tratan (venta sin promoción es un escenario de negocio válido)

Eliminación de duplicados:

953 filas duplicadas eliminadas de Fact_Ventas.

Eliminación de claves huérfanas:

300 filas eliminadas de Fact_Ventas (las 305 detectadas inicialmente, repetidas tras deduplicación).

Tratamiento de outliers:

- cantidad > 100 (240 registros) → corregido a la mediana (1.0)
- precio_unitario < 1 o > 1000 (240 registros) → corregido al precio_lista de referencia del producto

Derivación de métricas:

- importe = (cantidad * precio_unitario) - descuento
- costo = cantidad * costo_unitario
- margen = importe - costo

3.3.4. Resultado final

Métrica	Valor
Fact_Ventas final	59,700 filas

UNMSM - FISI - E.P. Ingeniería de Software
Inteligencia de Negocios
Proyecto Grupal

Importe total	S/ 4,453,561.59
Costo total	S/ 2,620,576.32
Margen total	S/ 1,832,985.27
Ticket promedio	S/ 74.60

3.4. Diccionario de Datos

Lo podemos encontrar en la carpeta de “datos/processed” ya que es un archivo .csv

	Tabla	Campo	Tipo	Clave	Descripción
0	Dim_Cliente	id_cliente	int	PK	Identificador único del cliente
1	Dim_Cliente	nombre	str		Nombre completo del cliente
2	Dim_Cliente	sexo	str		Sexo (M/F)
3	Dim_Cliente	fecha_nacimiento	date		Fecha de nacimiento
4	Dim_Cliente	distrito	str		Distrito de residencia
5	Dim_Cliente	fecha_alta	date		Fecha de alta en el programa
6	Dim_Cliente	segmento_programa	str		Segmento (Oro/Plata/Bronce/Sin Programa)

7	Dim_Producto	id_producto	int	PK	Identificador único del producto
8	Dim_Producto	nombre	str		Nombre del producto
9	Dim_Producto	categoria	str		Categoría del producto
10	Dim_Producto	subcategoria	str		Subcategoría
11	Dim_Producto	marca	str		Marca
12	Dim_Producto	precio_lista	float		Precio de lista
13	Dim_Producto	costo	float		Costo unitario

14	Dim_Tienda	id_tienda	int	PK	Identificador único de tienda
15	Dim_Tienda	nombre	str		Nombre comercial
16	Dim_Tienda	canal	str		Canal (físico/online)
17	Dim_Tienda	region	str		Región geográfica
18	Dim_Tienda	ciudad	str		Ciudad

UNMSM - FISl - E.P. Ingeniería de Software
Inteligencia de Negocios
Proyecto Grupal

19	Dim_Tiempo	fecha	date	PK	Fecha
20	Dim_Tiempo	dia	int		Día del mes (1-31)
21	Dim_Tiempo	mes	int		Mes (1-12)
22	Dim_Tiempo	trimestre	int		Trimestre (1-4)
23	Dim_Tiempo	anio	int		Año
24	Dim_Tiempo	dia_semana	str		Nombre del día de la semana
25	Dim_Tiempo	es_feriado	bool		Indica si es feriado


26	Dim_Promocion	id_promocion	int	PK	Identificador único de promoción
27	Dim_Promocion	nombre	str		Nombre de la promoción
28	Dim_Promocion	tipo	str		Tipo de promoción
29	Dim_Promocion	descuento_pct	float		Porcentaje de descuento
30	Dim_Promocion	fecha_inicio	date		Inicio de vigencia
31	Dim_Promocion	fecha_fin	date		Fin de vigencia

32	Fact_Ventas	id_venta	int	PK	Identificador único de venta
33	Fact_Ventas	fecha	date	FK	Fecha de venta -> Dim_Tiempo
34	Fact_Ventas	id_cliente	int	FK	Cliente -> Dim_Cliente
35	Fact_Ventas	id_producto	int	FK	Producto -> Dim_Producto
36	Fact_Ventas	id_tienda	int	FK	Tienda -> Dim_Tienda
37	Fact_Ventas	id_promocion	float	FK	Promoción -> Dim_Promocion (NaN = sin promo)
38	Fact_Ventas	cantidad	int		Cantidad vendida
39	Fact_Ventas	precio_unitario	float		Precio unitario aplicado
40	Fact_Ventas	descuento	float		Monto de descuento en soles
41	Fact_Ventas	importe	float		(cantidad * precio_unitario) - descuento
42	Fact_Ventas	costo	float		cantidad * costo_unitario
43	Fact_Ventas	margen	float		importe - costo

3.5. Captura del modelo en Power BI

Relaciones uno-a-muchos desde cada dimensión hacia Fact_Ventas, las columnas FK están ocultas en la vista del informe y se marcó Dim_Tiempo como tabla de fechas para inteligencia de tiempo.

UNMSM - FISI - E.P. Ingeniería de Software
Inteligencia de Negocios
Proyecto Grupal



4. Visualización de datos

4.1. Medidas DAX implementadas

4.1.1. KPIs Base

- **Ventas Totales:** Suma todo el ingreso de la botica ya descontando las promociones.

$Ventas\ Totales = SUM(Fact_Ventas[importe])$

- **Costo Total:** Suma los costos de los productos vendidos.

$Costo\ Total = SUM(Fact_Ventas[costo])$

- **Margen Bruto:** Es la ganancia neta en Soles.

$Margen\ Bruto = SUM(Fact_Ventas[margen])$

- **Margen Porcentual (%):** Porcentaje de las ventas que es ganancia real

4.1.2. Medidas Analíticas

- **Ticket Promedio:** Calcula cuánto gasta en promedio un paciente por cada boleta de compra.

Ticket Promedio = DIVIDE([Ventas Totales],
DISTINCTCOUNT(Fact_Ventas[id_venta]))

- **Cantidad de Productos por Ticket**

Productos por Ticket = DIVIDE(SUM(Fact_Ventas[cantidad]),
DISTINCTCOUNT(Fact_Ventas[id_venta]))

- **Total de Clientes Atendidos:** Cuenta cuántos clientes únicos han comprado en la botica.

Total Clientes = DISTINCTCOUNT(Fact_Ventas[id_cliente])

4.1.3. Inteligencia de Tiempo

- **Ventas Mes Anterior (MoM):**

Ventas Mes Anterior = CALCULATE([Ventas Totales],
DATEADD(Dim_Tiempo[fecha], -1, MONTH))

- **Crecimiento % (Respecto al mes anterior):**

Crecimiento % = DIVIDE([Ventas Totales] - [Ventas Mes Anterior],
[Ventas Mes Anterior], 0)


- **Ventas Acumuladas del Año (YTD):**

Ventas YTD = TOTALYTD([Ventas Totales], Dim_Tiempo[fecha])

4.2. Visualización

Como parte del análisis descriptivo del Datamart de Botica Los Andes, se desarrollaron visualizaciones orientadas a responder preguntas clave de negocio, identificando patrones de comportamiento en las ventas y oportunidades de mejora operativa.

4.2.1. Evolución Temporal y Estacionalidad



El gráfico de líneas ilustra la evolución de las ventas totales mensuales desde inicios del 2024 hasta principios del 2026. El análisis revela una estacionalidad altamente volátil con picos máximos de facturación que ocurren frecuentemente alrededor del mes de agosto (alcanzando su punto más alto con casi S/. 340,000 en 2024 y cerca de S/. 290,000 en 2025), seguidos por repuntes importantes a inicios de año, en el mes de enero.

En contraste, se identifican caídas drásticas (valles) que se repiten en dos momentos clave del año: entre marzo-mayo y hacia los meses de octubre-noviembre, periodos donde los ingresos totales descienden peligrosamente hacia el rango de los S/. 110,000 a S/. 150,000.


Implicancia estratégica:

Esta fuerte fluctuación exige a Botica Los Andes una planificación logística y comercial muy rigurosa.

- **Gestión de Inventarios:** El Centro de Distribución debe asegurar el abastecimiento máximo semanas antes de los picos históricos (preparándose en julio y diciembre) para evitar quiebres de stock cuando la demanda se dispara.

- **Acciones Comerciales:** Es urgente que el equipo de marketing diseñe estrategias de retención, promociones cruzadas o campañas de salud estacionales específicamente enfocadas en mitigar las caídas de marzo-mayo y octubre-noviembre, con el fin de estabilizar el flujo de caja operativo de la empresa durante esos meses críticos.

4.2.2. Análisis de Concentración (Principio de Pareto)




El diagrama de Pareto expone la regla del 80/20 aplicada al portafolio de Botica Los Andes. El hallazgo más destacable es el dominio absoluto de la categoría "Equipos Médicos", la cual por sí sola genera más de S/. 1.75 millones y representa más del 40% de los ingresos totales.

La línea de porcentaje acumulado (en rojo) demuestra que el 80% de la facturación recae en tan solo cinco agrupaciones: Equipos Médicos, Dermocosmética, Cuidado del Bebé, Suplementos y Vitaminas, y un alarmante quinto lugar correspondiente a ventas "Sin Categoría". Llama fuertemente la atención que agrupaciones tradicionalmente centrales en el rubro farmacéutico, como "Medicamentos" o "Insumos Médicos", se encuentren al final de la cola, aportando marginalmente a los ingresos brutos.

Implicancias estratégicas y recomendaciones:

- **Optimización Comercial y de Layout:** Al ser "Equipos Médicos" y "Dermocosmética" los verdaderos motores financieros de la empresa, estas categorías deben ocupar las "zonas calientes" (espacios de mayor visibilidad y tránsito) dentro de las tiendas físicas. El presupuesto de marketing y promociones debe reasignarse para potenciar estas líneas estrella.
- **Auditoría de Sistemas (Urgente):** El volumen de ingresos etiquetados como "Sin Categoría" (cerca de S/. 250,000) representa una falla crítica de calidad de datos en el origen. Se recomienda a la gerencia ordenar a TI una auditoría inmediata del sistema transaccional (Punto de Venta/ERP) para bloquear el uso de códigos genéricos por parte de los cajeros y forzar la correcta clasificación de los productos.
- **Revisión de Inventarios:** Dado el bajo rendimiento en ventas de "Medicamentos" e "Insumos Médicos", es vital cruzar esta información con el costo de almacenamiento. Si estas categorías de baja rotación ocupan mucho espacio en el almacén, se recomienda reducir su volumen de compra a proveedores para liberar capital de trabajo.

4.2.3. Mapa de Calor (Heatmap): Categorías vs. Meses

El mapa de calor ratifica el dominio constante de "Equipos Médicos" a lo largo de todo el año. Además, detalla que los picos de demanda del mes 7 (julio) y el mes 12 (diciembre) no dependen de una sola línea de productos, sino que representan un incremento generalizado en absolutamente todas las categorías. En contraste, se identifican meses de contracción severa del consumo, particularmente en febrero (2), abril (4) y septiembre (9).

Implicancias estratégicas y recomendaciones:

- **Sincronización Logística Total:** El área de compras debe elevar los niveles de inventario de *todo* el portafolio comercial durante junio y noviembre. Para los meses "fríos" (febrero, abril y septiembre), las órdenes de compra a proveedores deben reducirse al mínimo para evitar sobrestock e inmovilización de capital.

- **Estrategia de Ventas Cruzadas (Cross-selling):** Dado que el tráfico de clientes aumenta orgánicamente en julio y diciembre buscando "Equipos Médicos" (con ventas que superan los S/. 215,000), se debe aprovechar este flujo para lanzar promociones cruzadas (ej. descuentos en Suplementos o Medicamentos por la compra de un equipo), acelerando así la rotación de las categorías menos rentables.

5. Clasificación en BI

Se desarrolla un modelo de clasificación para predecir el abandono (churn) de los clientes del programa de fidelización de la botica, con el fin de anticipar qué clientes tienen mayor probabilidad de dejar de comprar y priorizar acciones de retención sobre ellos.

5.1. Definición del problema y variable objetivo

La variable objetivo es binaria: churn = 1 si el cliente abandonó el programa (dejó de registrar compras después de cierto punto de su historial), y churn = 0 si se mantiene activo. Esta variable ya viene calculada desde la etapa de generación de datos sintéticos y se toma directamente del datamart, sin recalcularla.

Sobre el total de 5,000 clientes del datamart, 1,071 están en abandono (21.4%) y 3,929 se mantienen activos (78.6%). Es un desbalance moderado, por lo que todos los modelos entrenados incorporan un manejo explícito de clases desbalanceadas (class_weight="balanced").

5.2. Construcción de variables (feature engineering)

Dado que Dim_Cliente por sí sola no explica el comportamiento de compra, se construyó una tabla analítica por cliente combinando sus datos demográficos con variables derivadas de Fact_Ventas, siguiendo una lógica extendida de RFM:

UNMSM - FISI - E.P. Ingeniería de Software
Inteligencia de Negocios
Proyecto Grupal

Variable	Descripción
Antigüedad (días)	Tiempo desde la fecha de alta del cliente hasta la fecha de referencia del análisis.
Recencia (días)	Días desde la última compra registrada.
Frecuencia	Número de boletas (tickets) distintas generadas por el cliente.
Monto total	Suma del importe de todas sus compras.
Ticket promedio	Monto total dividido entre la frecuencia.
N° de categorías	Cantidad de categorías de producto distintas que ha comprado.
% compras con promoción	Proporción de sus líneas de venta que se dieron dentro de una promoción vigente.
Edad	Calculada a partir de la fecha de nacimiento.
Sexo / Segmento del programa	Variables categóricas del perfil del cliente (Oro/Plata/Bronce/Sin Programa).

Se identificaron 324 clientes sin ninguna compra registrada (datos de alta en el programa pero sin actividad); para ellos las variables de comportamiento se completaron con 0 y su recencia se igualó a su antigüedad.

En el análisis exploratorio se confirmó que los clientes en abandono presentan, en promedio, mayor recencia y menor frecuencia y monto acumulado que los clientes activos, lo cual es consistente con la definición del churn. También se observó que la tasa de abandono es similar entre segmentos del programa (entre 20.2% en Bronce y 23.9% en Oro), sin una diferencia marcada; esto anticipa que el segmento por sí solo no es un buen predictor, algo que se confirma más adelante con la importancia de variables.

5.3. Comparación de modelos

Se entrenaron y compararon tres modelos de clasificación sobre una división estratificada 75/25 (3,750 clientes de entrenamiento y 1,250 de prueba), todos con semilla fija (42) para garantizar reproducibilidad:

Modelo	ROC-AUC	Precisión (churn=1)	Recall (churn=1)	F1 (churn=1)
Random Forest	0.863	0.551	0.660	0.601
Árbol de Decisión	0.841	0.442	0.806	0.571
Regresión Logística	0.831	0.476	0.780	0.591

Random Forest obtiene el mejor ROC-AUC, es decir, es el que mejor ordena a los clientes de mayor a menor riesgo de abandono, y también el mejor F1 de los tres modelos. Sin embargo, con el umbral de decisión estándar (0.5), su recall sobre la clase de interés sigue siendo el más bajo de los tres: clasificaría como "no abandono" a poco más de un tercio de

los clientes que en realidad se van. La Regresión Logística y el Árbol de Decisión priorizan más el recall (0.780 y 0.806, respectivamente), a costa de más falsos positivos.

5.4. Elección del modelo final

Se selecciona Random Forest como modelo final. La razón principal es el uso que se le da al resultado: el entregable de este análisis no es una etiqueta binaria automática, sino una probabilidad de abandono junto con un nivel de riesgo (Bajo/Medio/Alto) que alimenta el tablero de Power BI. Para ese propósito, importa más la capacidad del modelo de ordenar correctamente a los clientes según su riesgo real (lo que mide el ROC-AUC) que el resultado de un corte fijo en 0.5, y en este caso Random Forest además logra el mejor equilibrio general (F1) entre los tres modelos. Esto además permite que el equipo de retención amplíe o reduzca la cobertura de clientes atendidos ajustando el umbral de riesgo en el propio tablero, sin necesidad de reentrenar el modelo.

5.5. Interpretación del modelo

La importancia de variables del Random Forest final es la siguiente:

Variable	Importancia
Recencia	46.4%
Edad	10.9%
Antigüedad	9.9%
Monto total	8.9%
Ticket promedio	8.2%

UNMSM - FISI - E.P. Ingeniería de Software
Inteligencia de Negocios
Proyecto Grupal

Frecuencia	5.1%
% compras con promoción	4.1%
N° de categorías	3.4%
Sexo	1.3%
Segmento del programa	1.7% (suma de Plata/Oro/Sin Programa)

La recencia domina claramente el modelo, lo que confirma que el abandono en la botica está más ligado al comportamiento reciente de compra que al perfil del cliente. Las variables demográficas y de segmento aportan poco, con excepción de la edad, que aparece en segundo lugar; este resultado no tiene una lectura de negocio tan directa como la recencia, por lo que se recomienda no basar campañas de retención únicamente en la edad del cliente, sino usarla como un factor secundario dentro del modelo predictivo.

Sobre el conjunto de prueba (1,250 clientes), el modelo distribuye a los clientes en tres niveles de riesgo: 781 en riesgo Bajo (62.5%), 306 en riesgo Medio (24.5%) y 163 en riesgo Alto (13.0%). Esta tabla de probabilidades y niveles de riesgo se exporta para integrarse en la página de "Riesgo de abandono" del tablero de Power BI.

5.6. Recomendaciones de retención

A partir de los niveles de riesgo generados por el modelo, se proponen las siguientes acciones diferenciadas:

- **Riesgo Alto:** Contacto directo y personalizado (llamada o mensaje del farmacéutico/vendedor de confianza) ofreciendo un incentivo concreto de

reactivación (por ejemplo, descuento en su próxima compra o recordatorio de reposición de un tratamiento). Es un grupo acotado pero de alta probabilidad real de pérdida, por lo que justifica un esfuerzo de retención más costoso por cliente.

- **Riesgo Medio:** Campañas automatizadas de recordatorio (SMS/email) con cupones de menor valor o recordatorios de reposición de productos que compran habitualmente, buscando evitar que avancen a riesgo Alto.
- **Riesgo Bajo:** Mantener la comunicación estándar del programa de fidelización (acumulación de puntos, promociones generales), sin inversión adicional de retención, ya que el modelo indica baja probabilidad de abandono.
- Dado que la recencia es, por lejos, la variable más influyente, se recomienda que el disparador operativo de estas campañas sea automático: activar la comunicación de retención en cuanto un cliente supere un número de días sin comprar acorde a su patrón histórico, en lugar de esperar a una revisión periódica manual.
- No se recomienda usar el segmento del programa (Oro/Plata/Bronce) como criterio de priorización de retención, ya que el modelo muestra que tiene una relación muy débil con el abandono real; el segmento refleja el historial de fidelidad acumulado, pero no si el cliente sigue comprando actualmente.

6. Segmentación en BI

Segmentación de la base de clientes de la botica Los Andes utilizando algoritmos de Machine Learning (K-Means) sobre el datamart de ventas.

6.1. Variables RFM

Para comprender el comportamiento de los clientes, se ha decidido extender el modelo tradicional RFM para agregar variables específicas que vayan de acorde al modelo de negocio farmacéutico de la botica Los Andes..

Tabla RFM

UNMSM - FISl - E.P. Ingeniería de Software
Inteligencia de Negocios
Proyecto Grupal

Variable	Descripción
Recencia	Días transcurridos desde la última compra del cliente hasta la fecha actual del análisis, en la que un valor menor indica clientes más recientes y activos.
Frecuencia	Cantidad de tickets (boletas únicas) generados por el cliente en todo el historial, esta variable nos indica lealtad y recurrencia.
Monto	Suma total del importe gastado por el cliente (Ticket Acumulado).
Afinidad a Promociones	Porcentaje del importe total que el cliente gastó aprovechando algún descuento para identificar a los clientes que son sensibles al precio.
Afinidad a Medicamentos	Porcentaje del importe total gastado específicamente en la categoría de medicamentos, esto permite distinguir entre pacientes (compras de salud crónicas/agudas) y consumidores de cuidado personal/belleza.

6.2. Clusters

Se estandarizaron todas las variables para asegurar que el monto no opacara a la frecuencia o los porcentajes de afinidad. Posteriormente, se aplicó el algoritmo de agrupamiento K-Means.


Para determinar el número óptimo de grupos, se evaluaron métricas de Inercia con el método del Codo y el Coeficiente de Silueta.

En base a las gráficas obtenidas, según el método del codo, el número de clusters sería apropiado de 6 debido a que la curva empieza a suavizarse y la reducción de la inercia se

UNMSM - FISI - E.P. Ingeniería de Software
Inteligencia de Negocios
Proyecto Grupal

vuelve marginal en los siguientes valores. Además, según el gráfico de Coeficiente de Silueta, se observa que un valor de 6 en el número de clusters tiene un pico de 0.37, siendo este el más alto dentro del rango establecido por el método del codo, el cuál es de 3 a 6.

Método del Codo y Coeficiente de Silueta



6.3. Perfiles

Mediante la ejecución del modelo K-Means se obtuvo los siguientes 6 perfiles para el negocio:

Tabla de perfil de segmentos

	Tamaño	% del Total	Recencia	Frecuencia	Monto Acumulado	Afinidad Promos	Afinidad Medicamentos
Segmento							
En Riesgo (Solo Medicamentos)	195	4.2%	320 días	2.8	S/ 121	30%	72%
Cazadores de Ofertas	1,126	24.1%	307 días	4.8	S/ 335	86%	6%
Frecuentes Regulares	770	16.5%	58 días	28.2	S/ 2,133	34%	7%
Leales VIP / Crónicos	232	5.0%	99 días	79.4	S/ 5,964	32%	7%
Esporádicos / Desertores	864	18.5%	503 días	5.9	S/ 456	13%	5%
Esporádicos Recientes	1,489	31.8%	111 días	5.8	S/ 425	14%	6%

Análisis de los perfiles obtenidos:

- **Leales VIP / Crónicos (5%):** Es el segmento más valioso, ya que visitan la botica casi 80 veces y generan miles de soles de ingresos.
- **Frecuentes Regulares (16.5%):** Clientes que compran 28 veces y gastan más de S/ 2,000 en productos, formando parte de la "clase media-alta" del negocio.

UNMSM - FISI - E.P. Ingeniería de Software
Inteligencia de Negocios
Proyecto Grupal

- Cazadores de Ofertas (24.1%): Son clientes que acuden solo en campañas puntuales (su recencia promedio es de casi 1 año) y el 86% de su gasto se da en promociones..
- Esporádicos Recientes (31.8%): Clientes que gastan poco (S/ 425), pero han venido recientemente (112 días) y formando el segmento más grande.
- Esporádicos / Desertores (18.5%): Son clientes estancados debido a que no vienen hace más de 500 días.
- En Riesgo (4.2%): Clientes que utilizaron la botica por una urgencia médica, ya que el 72% de su gasto fue en medicamentos.

6.4. Estrategias

A partir de los 6 clusters definidos, se debe de implementar las siguientes acciones:

- A. Leales VIP / Crónicos: Implementar un programa de beneficios acelerados ("AndesPlus Oro") que ofrezca fila preferencial, delivery gratuito u ofertas en sus medicamentos crónicos.
- B. Frecuentes Regulares: Se puede sugerir productos dermo-cosméticos o productos de mayor margen al momento del pago y pasarlos a VIP.
- C. Esporádicos Recientes: Realizar un programa de fidelización enviando un cupón de "segunda compra" válido por 15 días o una recompensa de puntos, con la finalidad de que formen el hábito de volver para comprar otros productos.
- D. Cazadores de Ofertas: Tratarlos como clientes regulares pero motivarlos a comprar productos en ofertas enviando comunicaciones directas (SMS/Email) durante cierres de mes, CyberDays o campañas de descuentos ("Semana del Ahorro") para que puedan volver a comprar.
- E. En Riesgo: Dado que son clientes que solo compran productos cuando necesitan urgencias, no sería recomendable gastar presupuesto publicitario en este segmento.
- F. Esporádicos / Desertores: Dado que son clientes que llevan casi año y medio sin comprar, su costo de retención es alto, entonces, sería podría optar por enviar un

cupón de retención de un solo uso (ej. "Te extrañamos: 40% OFF"). En caso de que los clientes no lo usen, sería adecuado dejar de realizar envíos de marketing.

7. Asociación en BI

Se realiza el proceso de Análisis de Canasta de Compra de la botica "Los Andes" mediante la ejecución del algoritmo A priori para obtener las reglas de asociación.

7.1. Reglas de asociación

Se presentan las siguientes reglas de asociación con un lift superior a 1:

Antecedente	Consecuente	Confianza	Lift	Interpretación
Shampoo Anticaspa	Desodorante Roll-On	7.3%	2.03	Los compradores de shampoo anticaspa tienen el doble de probabilidad (Lift 2.03) de llevar desodorante respecto al cliente promedio.
Toallitas Húmedas X80	Talco Corporal	6.5%	1.98	Fuerte asociación de categoría "Cuidado Infantil / Bebé".
Paracetamol 500Mg	Colágeno Hidrolizado	6.8%	1.95	Combinación entre un producto para el dolor y un suplemento articular.
Desodorante Roll-On	Contorno de Ojos	3.8%	1.94	Relación en la categoría de rutinas de cuidado personal (Skincare/Higiene).
Crema Antipañalitis	Enjuague Bucal Menta	4.2%	1.90	Probablemente sean compras familiares o abastecimiento del

UNMSM - FISI - E.P. Ingeniería de Software
Inteligencia de Negocios
Proyecto Grupal

				hogar.
--	--	--	--	--------

La confianza nos indica la probabilidad condicional, por ejemplo, el 7.3% de las veces que se factura el Shampoo Anticaspa, en esa misma boleta va un Desodorante Roll-On.

7.2. Venta cruzada

Una vez que se tengan definidas las reglas de asociación, se puede diseñar las siguientes estrategias operativas para la botica:

- A. Ubicación física (Layout de Tienda): Colocar el "Talco Corporal" muy cerca (o en el mismo pasillo) de las "Toallitas Húmedas X80" y pañales. Esta estrategia tiene la finalidad de reducir la fricción de compra, ya que si el cliente va por toallitas, esto refuerza visualmente el producto que necesita comprar, como es el caso del Talco.
- B. Kits promocionales: Empaquetar juntos "Shampoo Anticaspa" y "Desodorante Roll-On" como un Kit de Higiene Personal con un descuento pequeño (ej. 10% de descuento al llevar ambos). La finalidad de la estrategia es armar un paquete que puede empujar el ticket promedio de los clientes que usualmente solo compraban uno de los dos.
- C. Sistema de recomendación en caja (Upsell): Se podría capacitar al personal de caja (farmacéuticos/técnicos) que el sistema marque que el cliente está llevando "Paracetamol 500Mg" y ofrecer "Colágeno Hidrolizado" u otros suplementos de prevención. La finalidad de esta estrategia es aprovechar la necesidad puntual de salud para realizar una venta cruzada de vitaminas/suplementos que tienen mayor margen de ganancia.

8. Regresión

8.1. Objetivo

Construir un modelo de regresión para pronosticar las ventas diarias (en soles) de la botica, utilizando datos históricos del datamart. El modelo permitirá apoyar la planificación de inventario y campañas promocionales.

8.2. Metodología

Para el desarrollo del modelo de regresión se siguieron los siguientes pasos:

- Carga de datos: se leyeron Fact_Ventas.csv (59,700 filas) y Dim_Tiempo.csv (730 días) desde data/processed/.
- Variable objetivo: se agregó el importe de todas las transacciones por día, obteniendo 730 registros diarios con un promedio de S/ 6,100.77 por día.
- Predictores (9 variables): dia_sem_num (0=lunes..6=domingo), mes, trimestre, es_feriado (0/1), pct_promo (% ventas con promoción), lag_1 (venta día anterior), lag_7 (venta 7 días atrás), rolling_7 (media móvil 7 días), tendencia (días desde el inicio). Tras crear rezagos y eliminar nulos, quedaron 723 filas.
- Split temporal 80/20: 578 días para entrenamiento (2024-01-08 a 2025-08-07) y 145 días para prueba (2025-08-08 a 2025-12-30).
- 3 modelos: Regresión Lineal (RL), Random Forest (RF, n=100), Gradient Boosting (GB, n=100).
- Métricas: MAE, RMSE, MAPE (%), R^2 .
- Interpretación y exportación: importancia de predictores (permutation importance), pronóstico semanal, y exportación a CSV.

8.3. Resultados

Modelo	MAE	RMSE	MAPE	R ²
Regresión Lineal	S/ 1,003.18	S/ 1,325.70	21.94%	0.586
Random Forest	S/ 1,228.27	S/ 1,503.16	29.10%	0.468
Gradient Boosting	S/ 3,492.11	S/ 3,812.70	87.66%	-2.421

Mejor modelo: Regresión Lineal (MAPE=21.94%, R²=0.586).

8.4. Importancia de predictores (Permutation Importance)

Predictor	Importancia
rolling_7	1.349
dia_sem_num	0.031
lag_7	0.009
pct_promo	0.004
mes	0.002
trimestre	0.001
lag_1	0.000

UNMSM - FISI - E.P. Ingeniería de Software
Inteligencia de Negocios
Proyecto Grupal

tendencia	-0.001
es_feriado	-0.002

Los predictores más influyentes son el promedio móvil de 7 días (rolling_7) y el día de la semana (dia_sem_num), reflejando estacionalidad semanal. El porcentaje de promociones (pct_promo) y el mes también tienen impacto, evidenciando el efecto de campañas y estacionalidad anual.

8.5. Pronóstico semanal

Día	Pronóstico
Día 1	S/ 7,036.53
Día 2	S/ 7,677.00
Día 3	S/ 7,499.14
Día 4	S/ 7,486.30
Día 5	S/ 7,704.27
Día 6	S/ 7,581.65
Día 7	S/ 7,812.94
Total semana	S/ 52,797.83

Promedio diario proyectado: S/ 7,542.55.

8.6. Integración con Power BI

Esta sección detalla la construcción de la solución de Inteligencia de

Negocios en Power BI Desktop.

- Gráfico comparativo: Se implementó un gráfico de líneas superpuestas que abarca el periodo de septiembre a diciembre de 2025. La línea azul sólida representa la evolución de las Ventas Reales, mientras que la línea naranja punteada ilustra el Pronóstico emitido por el modelo. Esta diferenciación visual permite a la gerencia identificar rápidamente las desviaciones y la tendencia al alza proyectada hacia el cierre del año.
- Métrica de evaluación (KPI): Para transparentar la precisión del modelo ante los tomadores de decisiones, se integró una tarjeta visual que destaca el Error Porcentual Absoluto Medio (MAPE). El indicador muestra un margen de error histórico del 21.94%, validando la viabilidad del modelo para planificaciones a corto plazo.
- Valor de Negocio y Planificación: Cumpliendo con el objetivo analítico, se incluyó un panel de recomendaciones accionables. Basado en la curva ascendente del pronóstico, se sugiere un aumento del 15% en los pedidos a proveedores para categorías de alta rotación (como Analgésicos y Vitaminas), con el fin de evitar quiebres de stock durante los próximos picos de demanda.


Comparativa: Venta Real vs. Ventas Pronósticada

Recomendaciones de Planificación:

El modelo predictivo anticipa un incremento de la demanda durante los próximos fines de semana, con un margen de error histórico del 21.9%. Para evitar quiebres de stock (desabastecimiento) en momentos críticos, se recomienda aumentar los pedidos a proveedores en un 15% para las categorías de alta rotación, como Analgésicos y Vitaminas, asegurando así la disponibilidad para el paciente.

21.94 %

MAPE



8.7. Recomendaciones de negocio

8.7.1. Recomendación de Planificación

Stock: El modelo predictivo anticipa un incremento de la demanda durante los próximos fines de semana, con un margen de error histórico del 21.9%. Para evitar quiebres de stock (desabastecimiento) en momentos críticos, se recomienda aumentar los pedidos a proveedores en un 15% para las categorías de alta rotación, como Analgésicos y Vitaminas, asegurando así la disponibilidad para el paciente

Operaciones: La curva de pronóstico indica una caída constante en el volumen de ventas durante los días martes y miércoles. Se sugiere a la gerencia optimizar los costos operativos programando los descansos del personal de mostrador en estos días valle.

Asimismo, se debe asegurar la cobertura máxima de farmacéuticos los días viernes y sábados, donde el modelo prevé los picos más altos de tráfico.

9. Reflexión ética y de integridad

La Inteligencia Artificial ha sido abordada desde una perspectiva de complementariedad para agilizar procesos como la generación de datos y la implementación de código, siempre ha estado bajo la supervisión de los integrantes del grupo. En los prompts de diseño del modelo dimensional, la IA actuó como un copiloto para establecer una estructura base (esquema estrella). Sin embargo, la integridad técnica y la responsabilidad final recae en el equipo, ya que se validaron y ajustaron el modelo (por ejemplo, definiendo el grano adecuado y agregando la dimensión Promoción) para asegurar que esté de acuerdo a las necesidades del negocio.

Se ha empleado la IA y librerías de Python (como Faker) para la generación de un conjunto de datos completamente sintético, para evitar exponer información sensible de clientes reales. Además, la generación de datos ha sido en base a una botica ficticia llamada “Los Andes”, lo cuál permite construir y probar modelos avanzados de segmentación, clasificación y pronóstico en BI sin comprometer la confidencialidad.

Finalmente, la integridad profesional se refleja en la manera en que se simuló el entorno de datos. En lugar de generar un conjunto de datos perfecto que ocultara los desafíos reales, se agregaron problemas de calidad (valores nulos, formatos inconsistentes, errores tipográficos y registros huérfanos). Esta decisión obliga a diseñar procesos de extracción, transformación y carga (ETL), enfrentando las imperfecciones de los datos de frente.

10. Conclusiones

El proyecto permitió implementar una solución integral de Inteligencia de Negocios para la botica "Los Andes", transformando datos de baja calidad en un modelo dimensional bajo un esquema estrella. A través del proceso ETL, se resolvieron problemas como la inconsistencia, duplicidad y valores atípicos, estableciendo una base de datos que, integrada en Power BI, ofrece a la gerencia una visión centralizada y precisa de las ventas. La implementación de analítica avanzada, abarcando la clasificación de riesgo de abandono, segmentación de clientes, análisis de asociación y pronóstico de ventas, ha permitido a la botica ficticia transitar hacia una gestión proactiva y orientada a datos. Al identificar patrones de comportamiento como la afinidad de canasta y los perfiles de riesgo, la organización puede ejecutar estrategias de marketing y retención, optimizando tanto la inversión promocional como la planificación de inventarios. Este marco de trabajo no solo mejora la rentabilidad y la atención al cliente, sino que también establece un estándar de integridad y ética en el manejo de datos dentro de la empresa.

Recomendaciones

Una de las mejoras es que se podría migrar hacia un entorno Cloud (como Azure, AWS o GCP) para garantizar escalabilidad, seguridad y automatización empresarial. En lugar de mantener el almacenamiento y procesamiento de datos de manera local, podría usarse un Data Lake en la nube y utilizar orquestadores como Apache Airflow o Azure Data Factory para automatizar las canalizaciones de datos. Ese cambio de arquitectura reduce el trabajo computacional de los equipos locales y ayuda a mantener volúmenes masivos de datos históricos, lo cual asegura que la infraestructura pueda crecer al igual que la expansión del negocio.


La segunda mejora sería evolucionar el ciclo de vida de los modelos predictivos implementando prácticas de MLOps (Machine Learning Operations). Actualmente se cuenta con algoritmos de clasificación (para la predicción de abandono), segmentación y regresión contenidos dentro de Jupyter Notebooks, pero se podría empaquetar y desplegar estos

modelos mediante plataformas como MLflow, facilitando su reentrenamiento automático a medida que se ingresan nuevos datos, el control de versiones de los modelos y su exposición como APIs.

Por último, se podría mejorar el gobierno de datos implementando un monitoreo proactivo de la calidad de la información, optando por herramientas automatizadas (como Great Expectations o dbt tests) integradas en el pipeline. Esta mejora permitiría generar alertas automáticas ante anomalías (como picos de valores nulos) antes de que estos errores lleguen al modelo dimensional y contaminen los tableros de Power BI.

Tabla de contribución por integrante

Todos los integrantes aportaron en la redacción del documento. A continuación se presenta la tabla del porcentaje de contribución de los integrantes en el proyecto:

Integrante	% Contri.	Tareas	Firma
Cisneros Culaca, David	20	Encargado de la parte 01 correspondiente al datamart y el desarrollo de la parte 6 de regresión	
Coronel Callupe, Giovanni	20	Encargado de la generación de datos y el dashboard de powerbi para la regresión	
Chávez Gave, Jose	20	Encargado de la parte 02 de visualización de datos y del dashboard	
Patricio Julca, Vilberto	20	Encargado de la segmentación y la asociación junto su dashboard correspondiente	
Tataje Gúzman, Kenner	20	Encargado de la parte 03 de clasificación y del dashboard correspondiente	

11. Cuadro de autoevaluación

11.1. Autoevaluación por componente

Componente	Punt. max.	Peso en PG	Autopuntaje (0-20)	Evidencia (archivo/sección)
Parte 1 - Datamart	20	20%	20	Informe, archivo 01_datamart
Parte 2 - Visualización	20	15%	20	Informe, archivo 02_visualizacion junto al dashboard powerbi
Parte 3 - Clasificación	20	16%	20	Informe y archivo 03_clasificacion
Parte 4 - Segmentación	20	16%	18	Informe y archivo 04_segmentacion
Parte 5 - Asociación	20	16%	18	Informe y archivo 05_asociacion
Parte 6 - Regresión	20	17%	20	Informe y archivo 06_regresion
Promedio ponderado de partes	20	80%	19	-
Rúbrica transversal	20	20%	18	Informe y exposición
PG estimado	20	100%	19	-

11.2. Lista de verificación

Criterio a verificar	Sí / Parcial / No	Evidencia	Brecha	Acción de mejora
Datos sintéticos reproducibles (semilla) y documentados	Si	Notebook 00_generacion_datos	Ninguna	Ninguna
ETL corrige los 7 problemas de calidad y reporta antes/después	Si	Notebook 01_datamart	Ninguna	Ninguna

Esquema estrella correcto y relaciones válidas en Power BI	Si	Archivo AndesMarket.pbix	Ninguna	Ninguna
Medidas DAX correctas y tablero con ≥ 4 páginas	Si	Archivo AndesMarket.pbix	Ninguna	Ninguna
Storytelling con ≥ 5 insights accionables	Si	Notebook 02_visualizacion e informe	Ninguna	Ninguna
Clasificación: comparación de modelos + métricas (incl. ROC-AUC)	Si	Notebook 03_clasificacion	Ninguna	Ninguna
Clasificación: interpretación y predicciones en Power BI	Si	Archivo AndesMarket.pbix	Ninguna	Ninguna
Segmentación: k justificado + perfilamiento + estrategias	Parcial	Notebook 04_segmentacion	Establecer las estrategias	Ninguna
Asociación: reglas con soporte/confianza/lift interpretadas	Si	Notebook 05_asociacion	Ninguna	Ninguna
Asociación: propuestas de venta cruzada	Parcial	Notebook 05_asociacion	Establecer las propuestas de venta cruzada del negocio	Ninguna
Regresión: validación temporal + MAE/RMSE/MAPE/R ² + pronóstico	Si	Notebook 06_regresion	Ninguna	Ninguna
Notebooks ejecutan de principio a fin	Si	Notebooks en el repositorio Git	Ninguna	Ninguna

sin errores				
Repositorio Git con commits de todos los integrantes	Si	Repositorio Git	Ninguna	Ninguna
Registro de prompts (Anexo A) e incluye generación de datos (Anexo B)	Si	Registro de prompts en el repositorio Git	Ninguna	Especificar más con capturas de pantalla de los prompts y archivo adjuntos en el uso de IA
Informe consolidado con la estructura del Anexo C	Si	Informe	Ninguna	Ninguna
Tabla de contribución por integrante	Si	Informe	Ninguna	Ninguna
Sustentación: cada integrante domina el conjunto	Parcial	Exposición	Algunas diferencias en los procedimientos que hizo cada integrante en cuanto al uso de IA	Reuniones grupales más frecuentes para coordinar detalles
Uso ético de IA declarado y código comprendido	Si	Informe y notebooks	Ninguna	Ninguna